Instituto Superior de Engenharia de Lisboa

Departamento de Engenharia Eletrónica e Telecomunicações e de Computadores (DEETC)

Mestrado em Engenharia Informática e de Computadores

Module of Practice #07
Support-for-FinalProject_B

Aprendizagem e Mineração de Dados (AMD)

1º Semestre – 2025/2026

Grupo 3

Autores:

Florin Sofinet (A46608)

Diogo Guerra (A49149)

Nuno Silva (A53976)

Índice

Introdução

1. Caso de estudo "e-commerce"

2. Criação de base de dados e população com o *dataset* "e-commerce"

3. Construção de *views* para analisar o *dataset* ("market-basket")

4. Exportar cesto para extrair regras de associação

5. Informação acerca do formato ".basket" e *string normalization*

6. Geração do formato ".basket" para representação da matriz esparsa

7. Análise do "market basket"

Conclusão

Introdução

Este laboratório foca-se num estudo de caso de *e-commerce* baseado no Projeto B com o objetivo de preparar os dados para a análise de cestos de compras. Com recurso ao PostgreSQL e ao Python, construir-se-ão tabelas, *views*, ficheiros <TID, PID> e ficheiros .basket compatíveis com o Orange, que nos permitirão explorar as regras de associação entre produtos e compreender o comportamento dos utilizadores neste contexto.

1. Caso de estudo "e-commerce"

a) O primeiro ponto consiste na análise do ficheiro z_dataset_sample.txt, que contém um subconjunto dos eventos do "e-commerce" descrito no Projeto B.

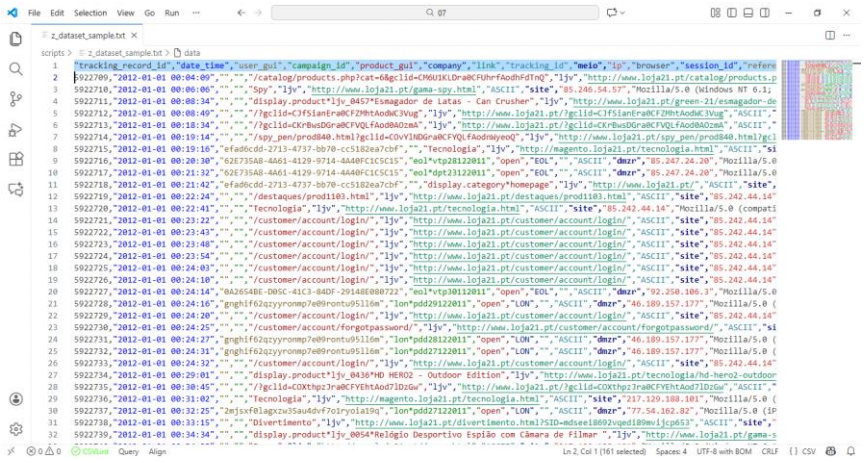


Figura 1. Excerto do ficheiro z_dataset_sample.txt com a estrutura dos eventos de e-commerce.

2. Criação de base de dados e população com o *dataset* "e-commerce"

a) Neste passo é criada a base de dados que suportará a anáise dos eventos de *e-commerce*.

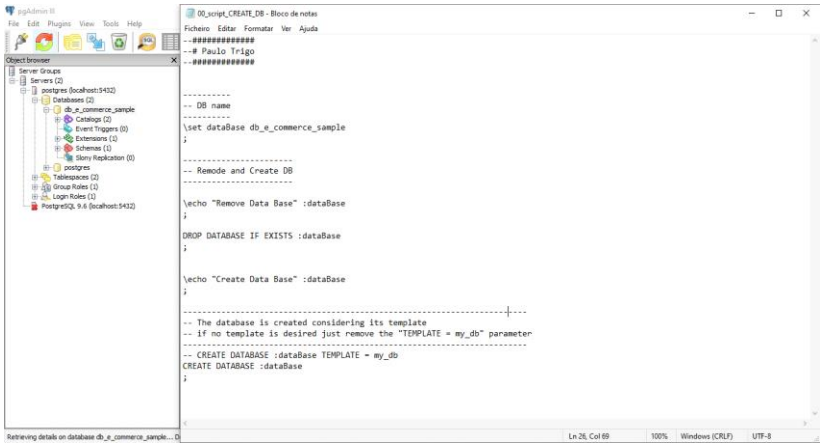


Figura 2. Criação da base de dados db_e_commerce_sample a partir do script.

b) Nesta alínea é criado o esquema da base de dados, em particular a tabela track que armazenará os eventos de navegação do *e-commerce*.

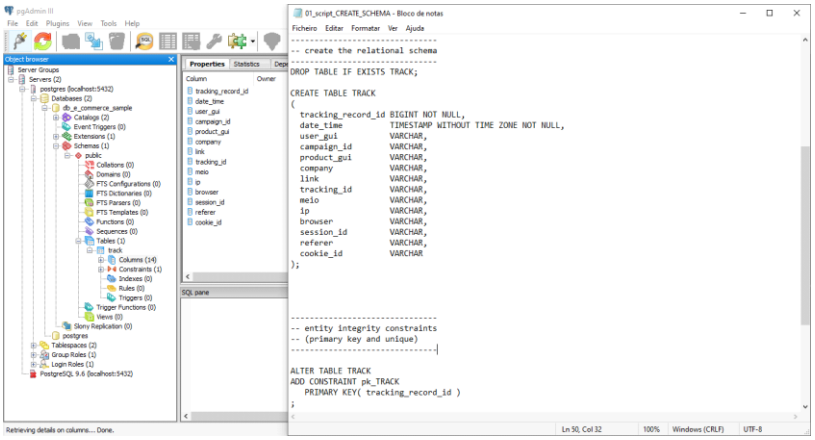


Figura 3. Criação da tabela track na base de dados db_e_commerce_sample.

c) Aqui é ajustado o script de importação dos eventos do *e-commerce*- para a tabela track e é feito o carregamento dos dados.

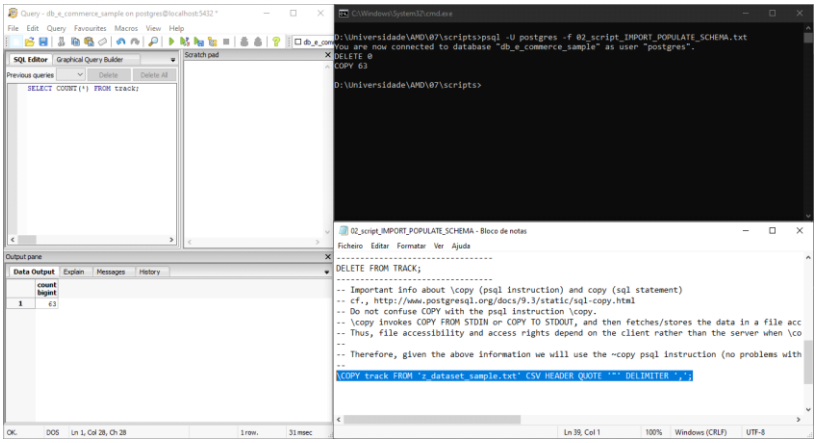


Figura 4. Importação do *dataset* z_dataset_sample.txt para a tabela track.

3. Construção de *views* para analisar o *dataset* ("market-basket")

a) Aqui criamos a *view* v_cookie_session_number_of_events que contém os eventos da tabela track por cookie_id e session_id, relativos ao número de eventos por visitante e sessão.

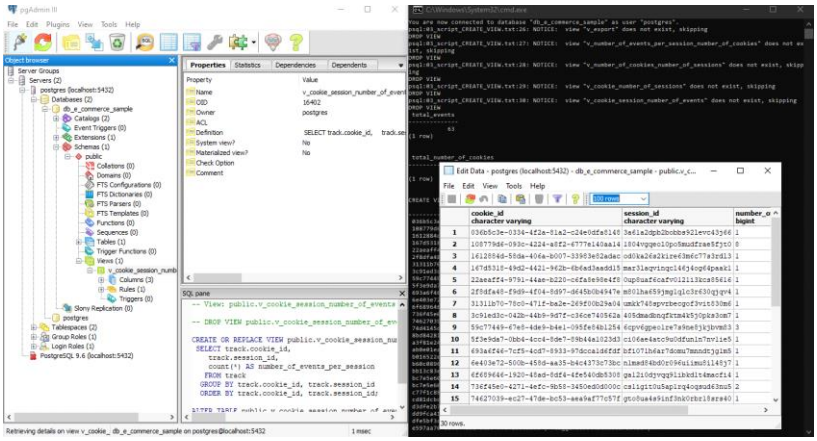


Figura 5. *View* v_cookie_session_number_of_events e resultados com o número de eventos por *cookie* e sessão.

b) Nesta alínea é criada a *view* v_cookie_number_of_sessions, que contém a informação por visitante (cookie_id), com o número total de visitantes e o total de eventos associado a cada um.

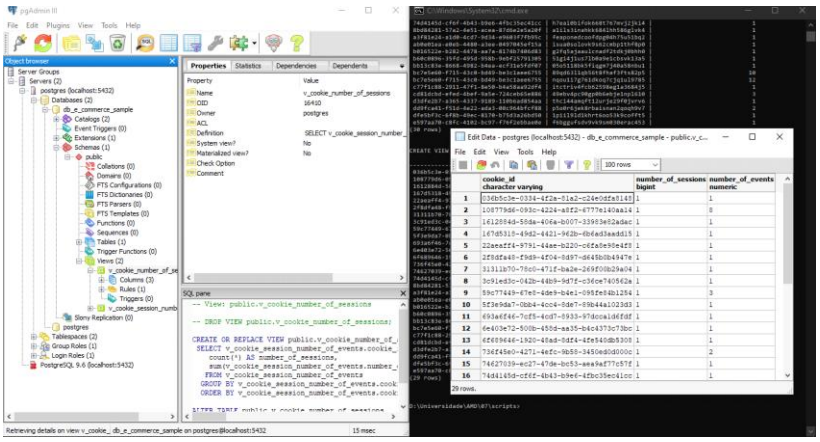


Figura 6. *View* v_cookie_number_of_sessions com o número de sessões e eventos agregados por cookie..

c) Neste passo construimos a *view* v_number_of_cookies_number_of_sessions, que contém o número total de sessões e conta quantos visitantes têm exatamente cada uma dessas quantidades de visitas.

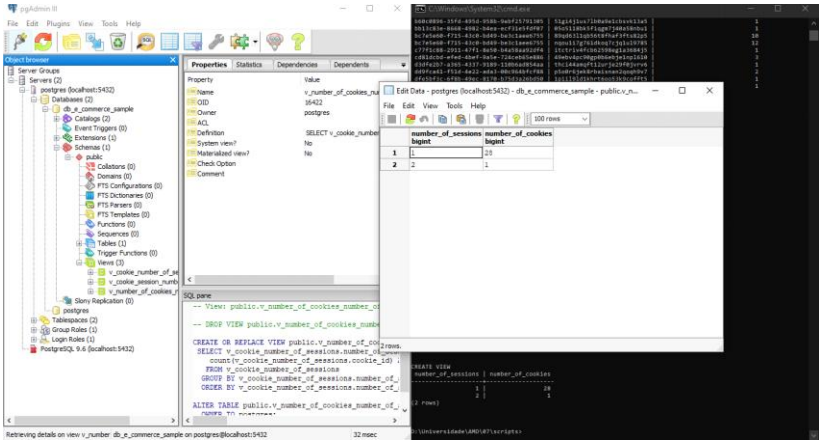


Figura 7. *View* v_number_of_cookies_number_of_sessions com quantos cookies têm cada número de sessões.

d) Aqui construimos a view v_number_of_events_per_session_number_of_cookies, que contém o número de eventos por sessão e contabiliza o número de visitantes associados a cada valor.

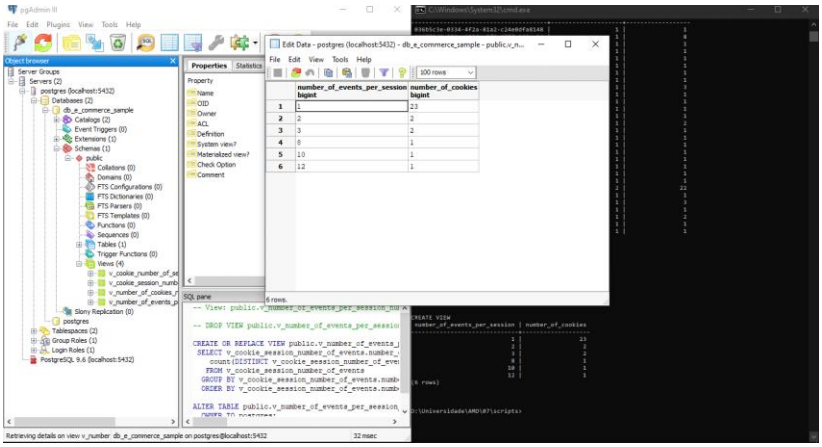


Figura 8. *View* v_number_of_events_per_session_number_of_cookies com a distribuição do número de eventos por sessão e número de cookies.

e) Nesta alínea validam-se as views criadas, comparando o respetivo output com o ficheiro de referência z_VIEW_expected.txt.



Figura 9. Validação das views criadas, comparadas com o ficheiro z_VIEW_expected.txt.

Os resultados coincidem com o esperado.

4. Exportar cesto para extrair regras de associação

a) Nesta alínea ativou-se a *view* v_export, que define a estrutura fundamental dos cestos.

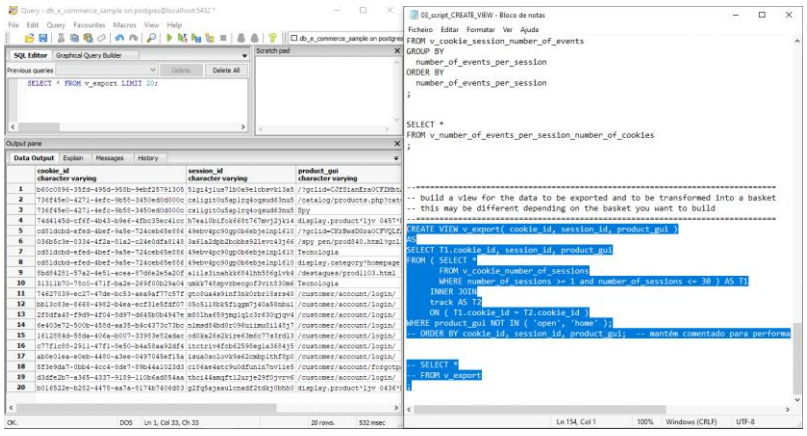


Figura 10. Ativação e teste da *view* v_export.

b) Neste ponto altera-se o *script* de exportação de forma a garantir que os dados seguem a formulação <TID,PID>, exigido pelo *Market Basket Analysis*.

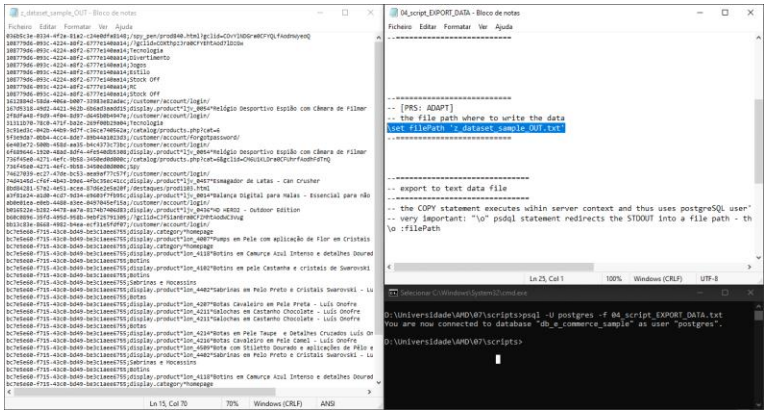


Figura 11. Exportação do *dataset* no formato <TID,PID> com a *view* v_export.

c) Aqui o ficheiro exportado é comparado com o ficheiro z_dataset_sample_OUT_expected.txt de forma a confirmar que os pares <cookie_id, product_gui> gerados pela *view* v_export correspondem ao esperado.

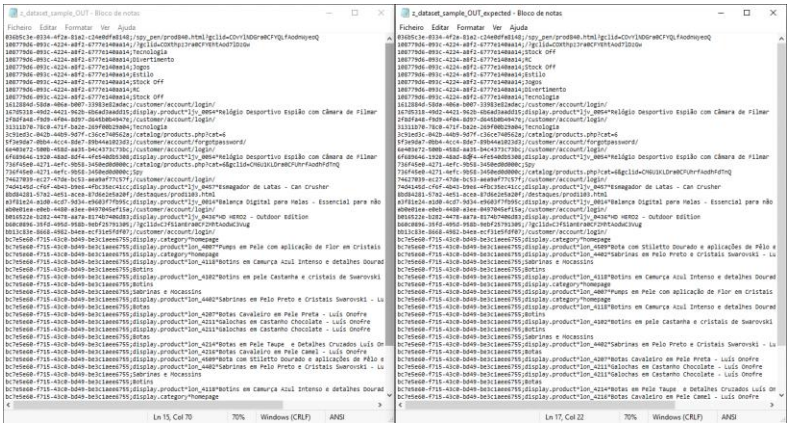


Figura 12. Comparação entre o ficheiro exportado e o ficheiro de referência..

5. Informação acerca do formato ".basket" e *string normalization*

a) Antes de gerar o ficheiro .basket, é necessário compreender o formato utilizado pelo Orange em problemas deste tipo. O formato .basket é uma forma de matriz dispersa que identifica os itens presentes em cada transação.

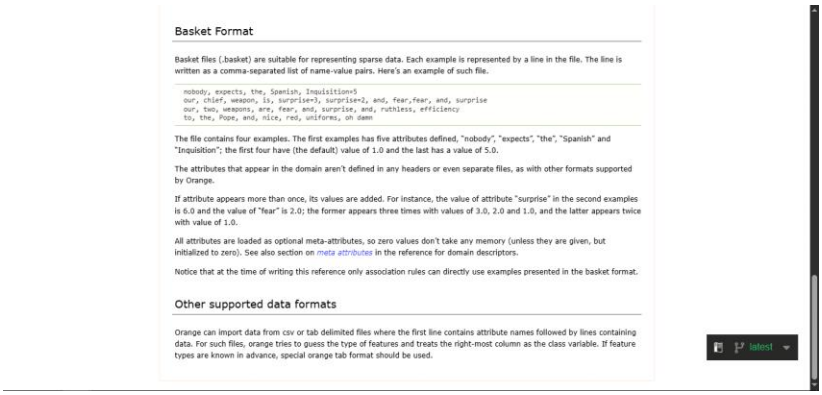


Figura 13. Secção *Basket Format* da documentação do Orange.

O formato .basket representa cada transação numa única linha, onde aparecem todos os produtos associados a essa transação. Não existe cabeçalho e os itens são separados por espaços. Cada linha corresponde a um TID, agindo como uma matriz dispersa, sendo depois transformada pelo Orange, onde cada item se transforma numa coluna e cada transação numa linha. Todas as *strings* têm de ser normalizadas: sem espaços, acentos ou caracteres especiais e impossibilidade de misturar maiúsculas e minúsculas.

b) Antes da geração do .basket, analisamos as strings dos atributos exportados, nomeadamente o campo product_gui, porque alguns valores podem conter caracteres ou formatos incompatíveis com o Orange, o que obriga à normalização.



Figura 14. Exemplos de valores problemáticos em product_gui que requerem normalização.

6. Geração do formato ".basket" para representação da matriz esparsa

a) Nesta etapa fazemos a ligação entre a base de dados e os algoritmos de regras de associação do Orange, através de um *script* Python que seja capaz de ler o ficheiro exportado, normalizar as *strings* para ir ao encontro do formato .basket e gerar automaticamente o ficheiro final no formato adequado.

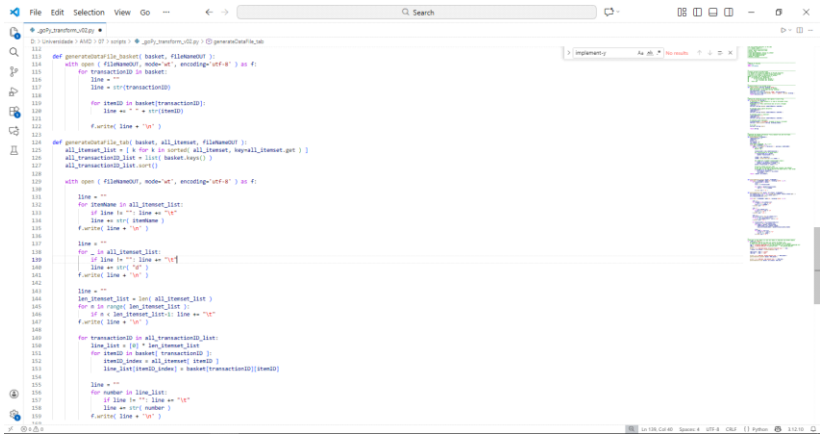


Figura 15. Implementação da função de normalização.

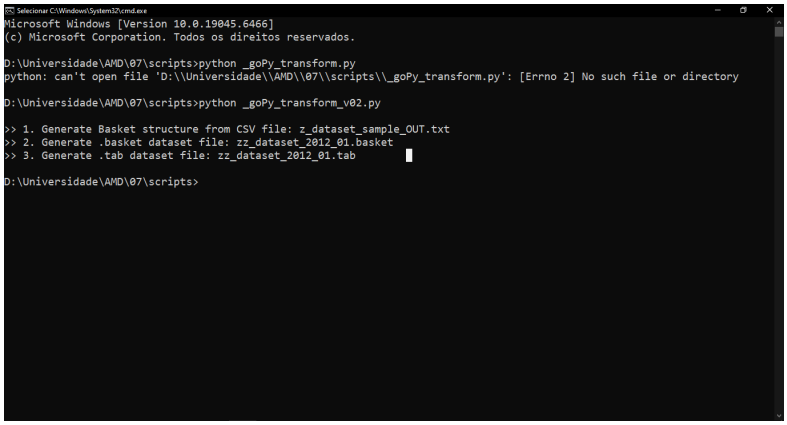


Figura 16. Execução do *script* e geração do ficheiro .basket.

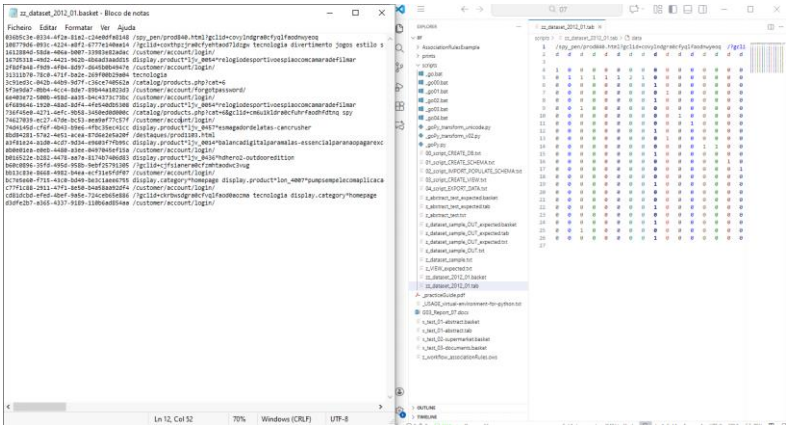


Figura 17. Ficheiros .basket e .tab gerados.

b) Nesta alínea valida-se o ficheiro .basket gerado, comparando-o com o ficheiro fornecido.

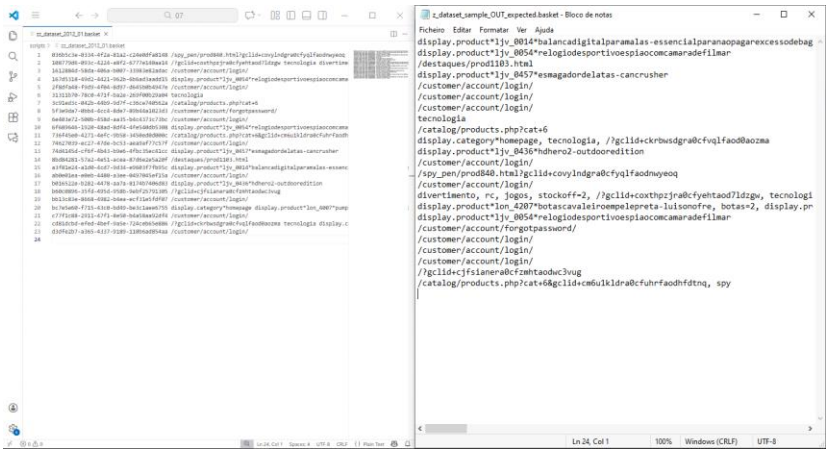


Figura 18. Comparação entre o ficheiro .basket gerado e o ficheiro fornecido.

A validação confirmou que o ficheiro gerado contém a mesma informação semântica do ficheiro de referência, embora estruturada de forma distinta.

7. Análise do "market basket"

a) Nesta fase utilizamos o Orange para fazer uma *market basket analysis*.

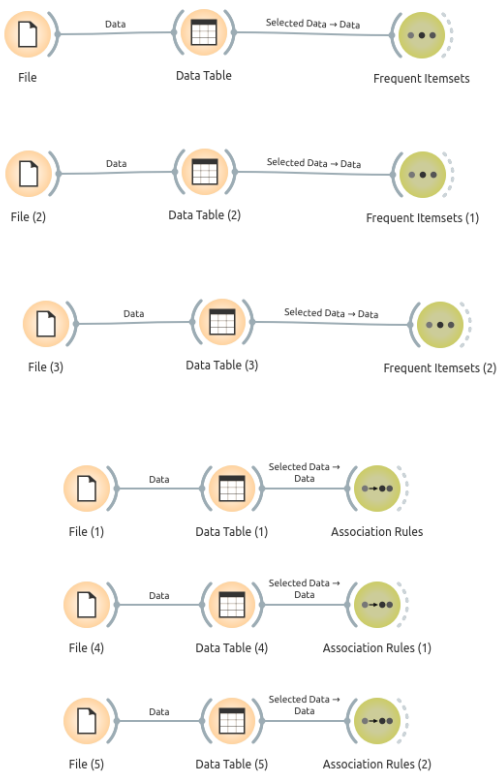


Figura 19. *Workflow* completo.

A seguir vai ser apresentado as seguintes imagens de itemsets frequentes e regras de associação para cada workflow sabendo que a percentagem de suporte é de 25%, a percentagem de confiança é de 80% e o máximo número de regras são até 10000 regras.

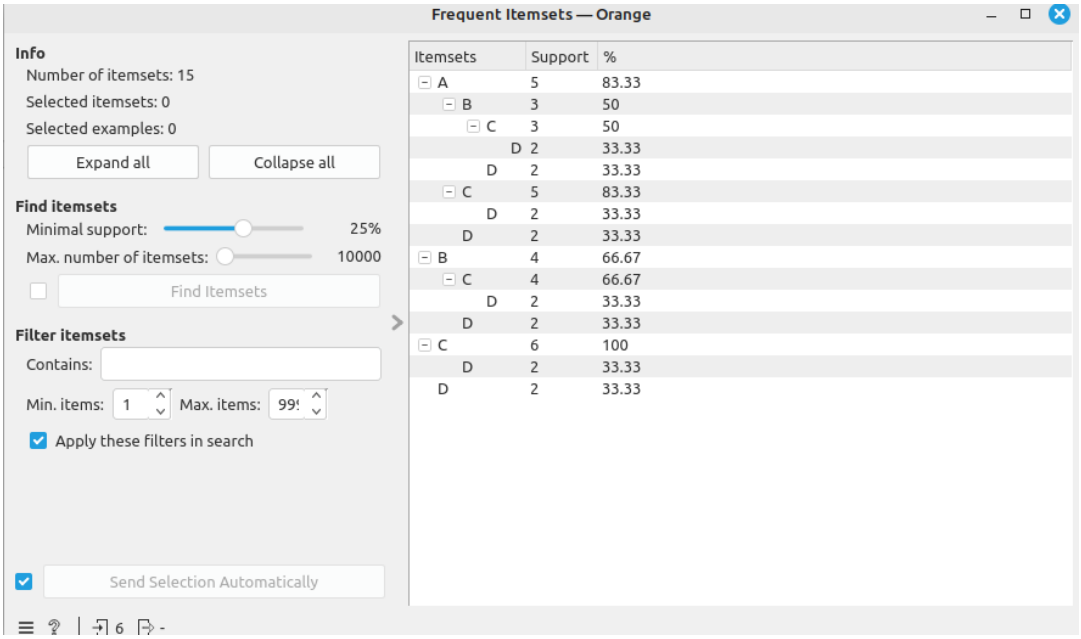


Figura 20. Resultados de *Frequent Itemsets* obtidos a partir do ficheiro x_test_01-abstract.

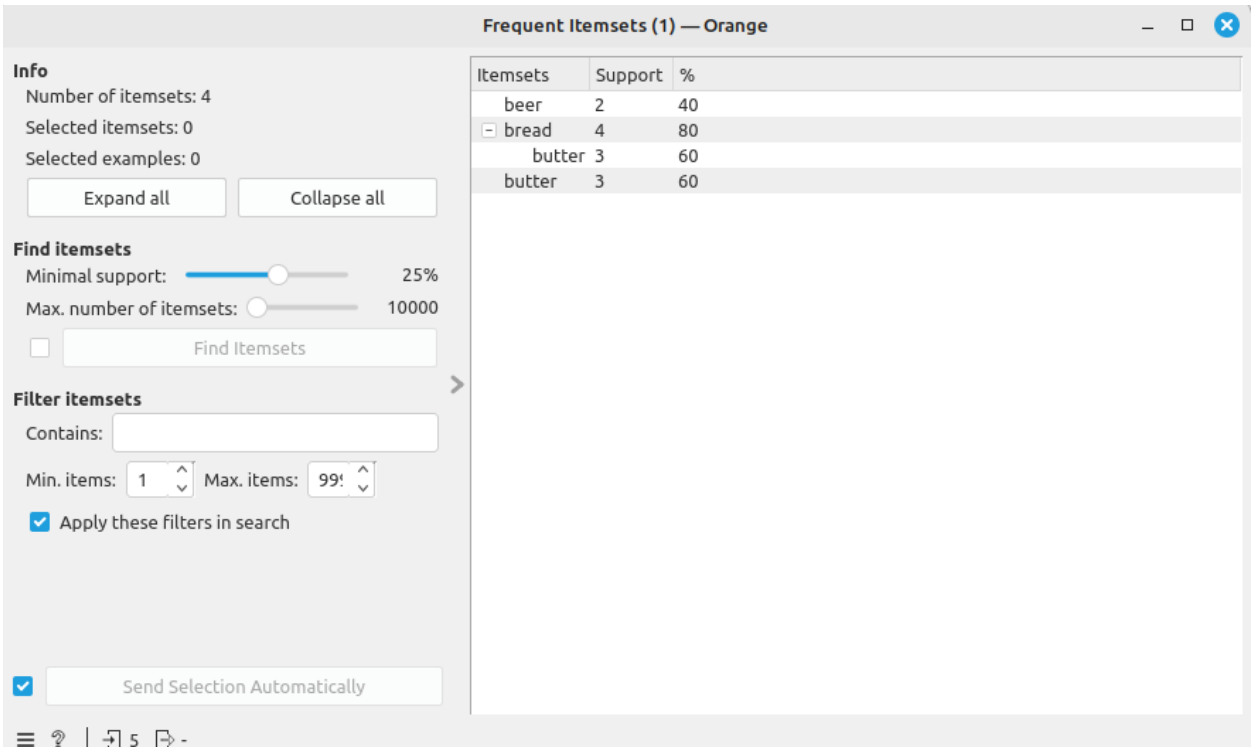


Figura 21. Resultados de *Frequent Itemsets* obtidos a partir do ficheiro x_test_02-supermarket.

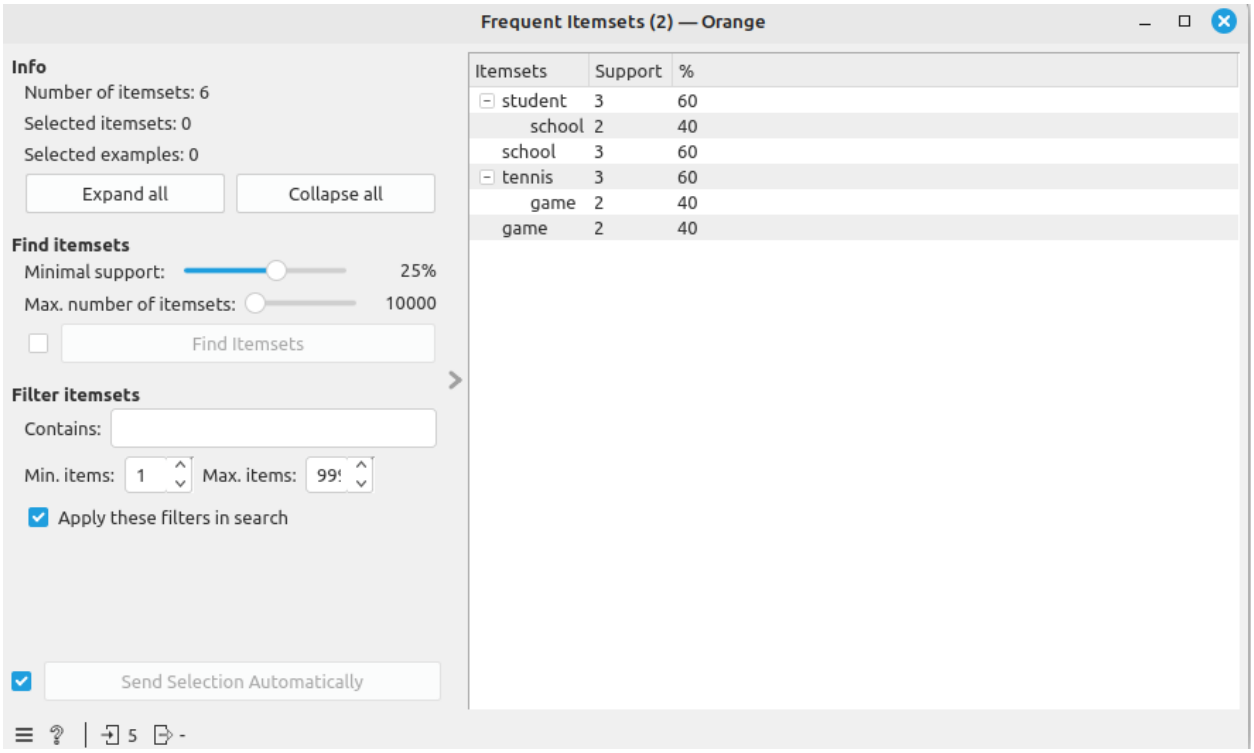
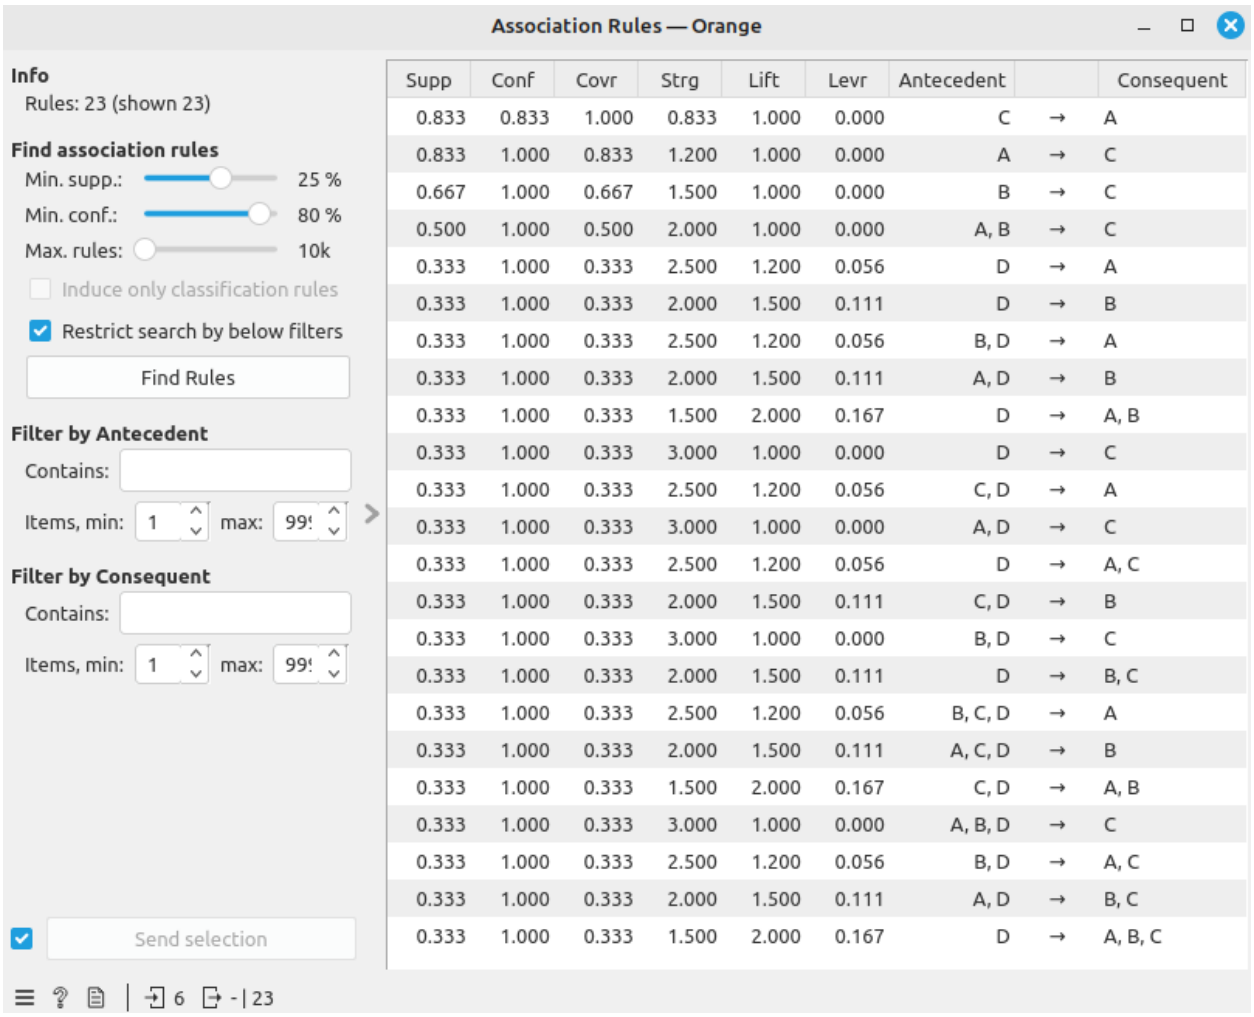


Figura 22. Resultados de *Frequent Itemsets* obtidos a partir do ficheiro x_test_03-documents.



Supp	Conf	Covr	Strg	Lift	Levr	Antecedent		Consequent
0.833	0.833	1.000	0.833	1.000	0.000	C	→	A
0.833	1.000	0.833	1.200	1.000	0.000	A	→	C
0.667	1.000	0.667	1.500	1.000	0.000	B	→	C
0.500	1.000	0.500	2.000	1.000	0.000	A, B	→	C
0.333	1.000	0.333	2.500	1.200	0.056	D	→	A
0.333	1.000	0.333	2.000	1.500	0.111	D	→	B
0.333	1.000	0.333	2.500	1.200	0.056	B, D	→	A
0.333	1.000	0.333	2.000	1.500	0.111	A, D	→	B
0.333	1.000	0.333	1.500	2.000	0.167	D	→	A, B
0.333	1.000	0.333	3.000	1.000	0.000	D	→	C
0.333	1.000	0.333	2.500	1.200	0.056	C, D	→	A
0.333	1.000	0.333	3.000	1.000	0.000	A, D	→	C
0.333	1.000	0.333	2.500	1.200	0.056	D	→	A, C
0.333	1.000	0.333	2.000	1.500	0.111	C, D	→	B
0.333	1.000	0.333	3.000	1.000	0.000	B, D	→	C
0.333	1.000	0.333	2.000	1.500	0.111	D	→	B, C
0.333	1.000	0.333	2.500	1.200	0.056	B, C, D	→	A
0.333	1.000	0.333	2.000	1.500	0.111	A, C, D	→	B
0.333	1.000	0.333	1.500	2.000	0.167	C, D	→	A, B
0.333	1.000	0.333	3.000	1.000	0.000	A, B, D	→	C
0.333	1.000	0.333	2.500	1.200	0.056	B, D	→	A, C
0.333	1.000	0.333	2.000	1.500	0.111	A, D	→	B, C
0.333	1.000	0.333	1.500	2.000	0.167	D	→	A, B, C

Figura 23. Regras de associação geradas obtidos a partir do ficheiro x_test_01-abstract.

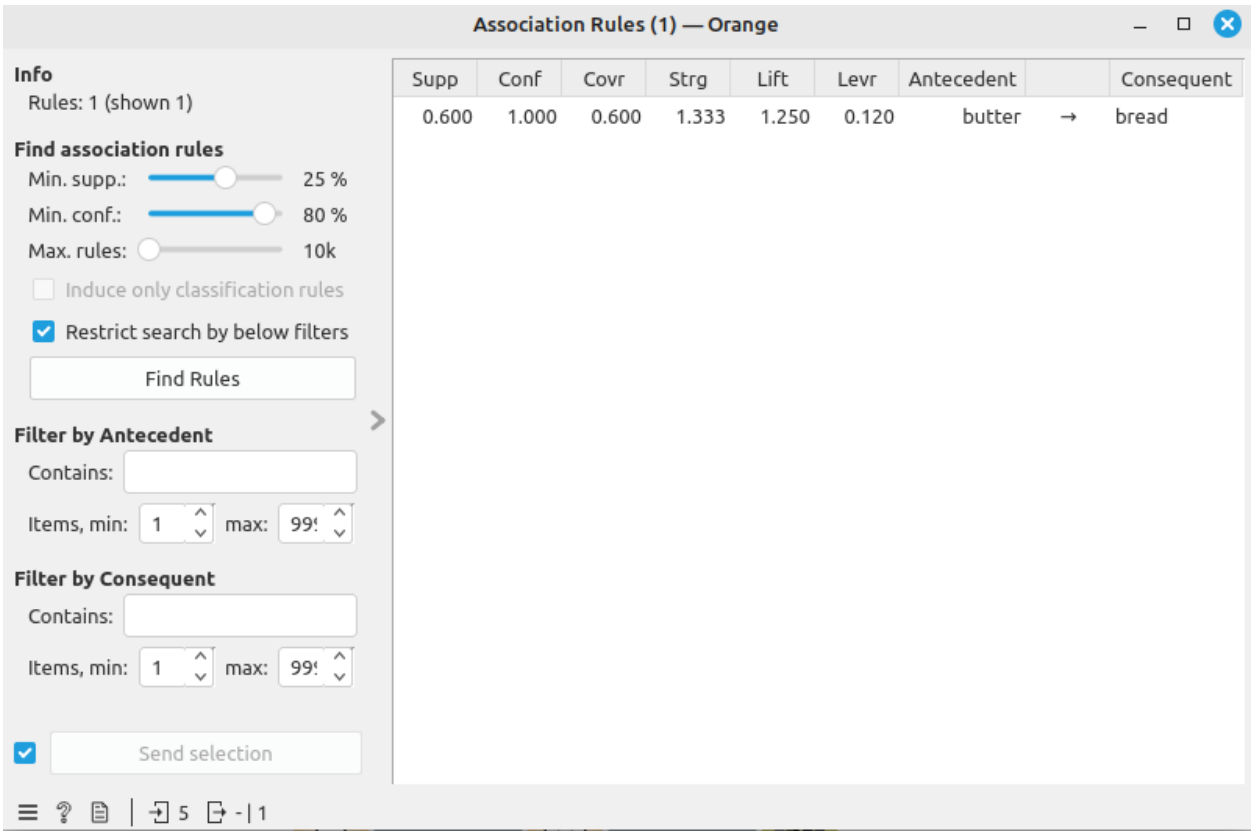


Figura 24. Regras de associação geradas obtidos a partir do ficheiro x_test_02-supermarket.

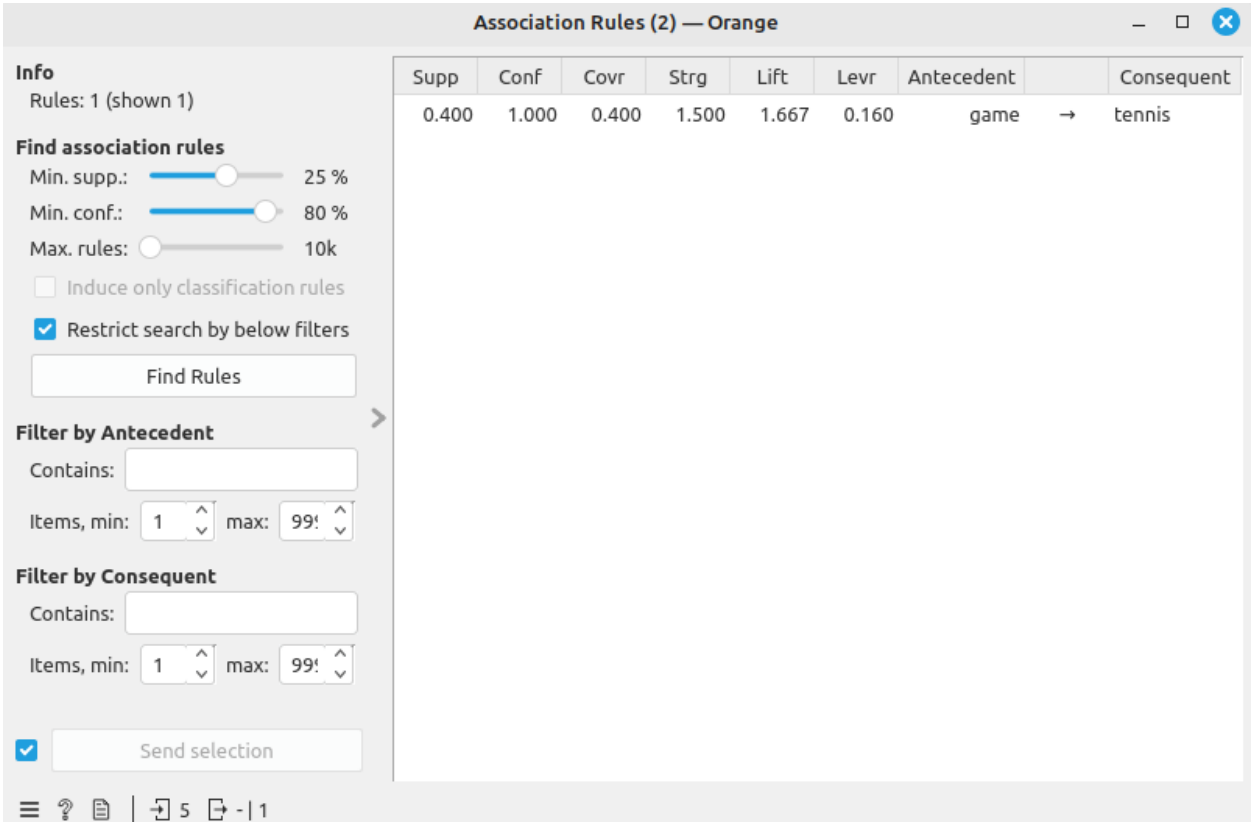


Figura 25. Regras de associação geradas obtidos a partir do ficheiro x_test_03-documents.

Observations:
Com um suporte moderado (25%) e uma confiança elevada (80%), o algoritmo identificou com sucesso regras de associação fortes. Os resultados variam significativamente consoante as características dos conjuntos de dados - o conjunto de dados abstrato produziu o maior número de regras, enquanto os conjuntos de dados do mundo real (supermercado, documentos) produziram menos associações, mas mais interpretáveis.

b) Para complementar a abordagem do Orange, explorou-se uma implementação programática da extração de regras de associação feita em python. A implementação está localizada na diretoria "scripts" e o seu ficheiro chama-se "associations_rules.py".

```
================================================================================
ASSOCIATION RULES ANALYSIS - Exercise 7b
================================================================================
Global parameters:
  - Support: 25.0%
  - Confidence: 80.0%
================================================================================

================================================================================
Processing: x_test_01-abstract.basket
================================================================================

Dataset loaded: 6 transactions
Minimum support: 25.0% = 2 transactions
Minimum confidence: 80.0%

--- Frequent Itemsets (min support = 2) ---
Number of frequent itemsets: 15

Frequent itemsets (decoded):
  ['C'] -> support: 6 (100.00%)
  ['A'] -> support: 5 (83.33%)
  ['A', 'C'] -> support: 5 (83.33%)
  ['B'] -> support: 4 (66.67%)
  ['B', 'C'] -> support: 4 (66.67%)
  ['A', 'B'] -> support: 3 (50.00%)
  ['A', 'B', 'C'] -> support: 3 (50.00%)
  ['D'] -> support: 2 (33.33%)
  ['A', 'D'] -> support: 2 (33.33%)
  ['B', 'D'] -> support: 2 (33.33%)
  ['A', 'B', 'D'] -> support: 2 (33.33%)
  ['C', 'D'] -> support: 2 (33.33%)
  ['A', 'C', 'D'] -> support: 2 (33.33%)
  ['B', 'C', 'D'] -> support: 2 (33.33%)
  ['A', 'B', 'C', 'D'] -> support: 2 (33.33%)

--- Association Rules (min confidence = 0.8) ---
Number of association rules: 23
```

Figura 26. Output da implementação programática feita em python (Parte 1).

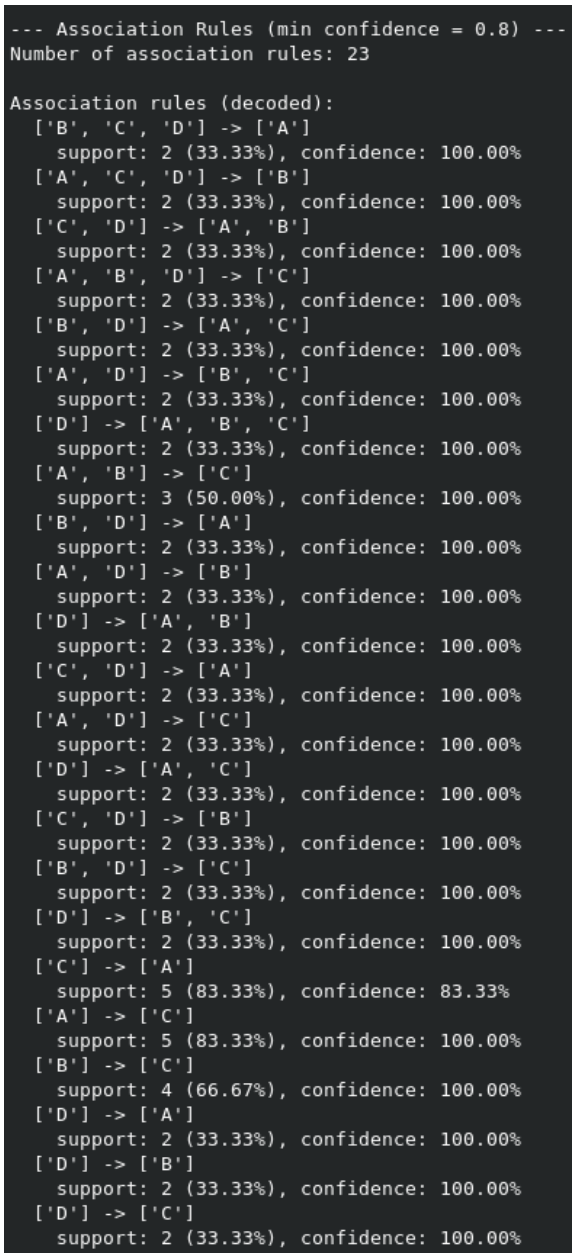


Figura 26. Output da implementação programática feita em python (Parte 2).

```
================================================================================
Processing: x_test_02-supermarket.basket
================================================================================

Dataset loaded: 5 transactions
Minimum support: 25.0% = 2 transactions
Minimum confidence: 80.0%

--- Frequent Itemsets (min support = 2) ---
Number of frequent itemsets: 4

Frequent itemsets (decoded):
  ['bread'] -> support: 4 (80.00%)
  ['butter'] -> support: 3 (60.00%)
  ['bread', 'butter'] -> support: 3 (60.00%)
  ['beer'] -> support: 2 (40.00%)

--- Association Rules (min confidence = 0.8) ---
Number of association rules: 1

Association rules (decoded):
  ['butter'] -> ['bread']
    support: 3 (60.00%), confidence: 100.00%

================================================================================
Processing: x_test_03-documents.basket
================================================================================

Dataset loaded: 5 transactions
Minimum support: 25.0% = 2 transactions
Minimum confidence: 80.0%

--- Frequent Itemsets (min support = 2) ---
Number of frequent itemsets: 6

Frequent itemsets (decoded):
  ['student'] -> support: 3 (60.00%)
  ['school'] -> support: 3 (60.00%)
  ['tennis'] -> support: 3 (60.00%)
  ['student', 'school'] -> support: 2 (40.00%)
  ['game'] -> support: 2 (40.00%)
  ['tennis', 'game'] -> support: 2 (40.00%)

--- Association Rules (min confidence = 0.8) ---
Number of association rules: 1

Association rules (decoded):
  ['game'] -> ['tennis']
    support: 2 (40.00%), confidence: 100.00%

================================================================================
Analysis complete!
================================================================================
```

Figura 26. Output da implementação programática feita em python (Parte 3).

Conclusão

A realização deste laboratório permitiu aplicar de forma integrada várias competências desenvolvidas ao longo da unidade curricular, aplicadas ao contexto de *e-commerce* e *market basket analysis*: construção de bases de dados, análise de eventos, construção de *views*, normalização automática de dados e preparação e geração de ficheiros compatíveis com o Orange.

O processo evidenciou a importância da preparação de dados antes da descoberta de padrões, nomeadamente através da eliminação de ruído, normalização de cadeias e construção de matrizes esparsas, e, novamente, a utilização combinada de código e ferramentas visuais evidenciou a complementaridade entre as duas abordagens.

O laboratório proporcionou, assim, uma visão geral do *pipeline* para analisar o comportamento de sistemas reais de *e-commerce*.