Instituto Superior de Engenharia de Lisboa

Departamento de Engenharia Eletrónica e Telecomunicações e de Computadores (DEETC)

Mestrado em Engenharia Informática e de Computadores

FINAL PROJECT - A

Aprendizagem e Mineração de Dados (AMD)

1º Semestre – 2025/2026

Grupo 3

Autores:

Diogo Guerra (A49149)

Nuno Silva (A53976)

Florin Sofinet (A46608)

Segunda-feira, 27 de outubro de 2025

Índice

1. Introdução
2. Processamento e preparação dos dados:
    2.1. Análise dos dados
    2.2. Desenvolvimento da base de dados
    2.3. Inserção e visualização dos dados
    2.4. Exportação
    2.5. Algoritmo 1R
    2.6. Algoritmo ID3 e Naïve Bayes
    2.7. Avaliações métricas
3. Conclusão

1. Introdução

Este projeto foca-se na exploração da relação entre os dados, a informação e o conhecimento. Trataremos um dataset específico e aplicaremos métodos como o 1R, o ID3 e o Naïve Bayes. Para a análise, são utilizados sistemas de gestão de dados (PostgreSQL), ferramentas de mineração de dados (Orange) e scripts em Python para implementação de algoritmos.

O contexto do projeto é o centro médico "MedKnow", que mantém um histórico detalhado de visitas de pacientes e de outros dados essenciais ao seu funcionamento. A equipa de oftalmologia pretende extrair padrões desses dados que auxiliem tanto na prescrição diária de lentes quanto em decisões a partir de indicadores derivados do histórico clínico.

O objetivo é, então, desenvolver uma proposta que melhore e agilize a gestão dos clientes por parte do "MedKnow".

2. Processamento e Preparação dos dados

Esta secção servirá como o "desenvolvimento" do projeto, já que aqui constam todos os procedimentos que nos permitem realizar cada um dos itens propostos, de forma a podermos chegar a quaisquer conclusões. Analisaremos o conjunto de dados enviado pelo "MedKnow" e faremos os modelos e representações necessários à sua total compreensão. Aqui figurarão as metodologias, as técnicas e os algoritmos desenvolvidos.

2.1. Análise dos dados

O dataset fornecido corresponde ao registo de consultas oftalmológicas, com dados relativos à idade do paciente, à prescrição, à presença ou ausência de astigmatismo, à taxa lacrimal e às lentes atribuídas. Perante estes dados, procurámos encontrar padrões entre as instâncias, de forma a criar regras informais para classificar o dataset, antes de prosseguir para uma análise mais aprofundada. Sendo *lenses* a classe, conseguimos apenas concluir que quando *tear_rate = reduced* nenhuma lente é atribuída – como podemos verificar abaixo –, o que, ainda assim, não constitui uma regra suficientemente forte. Para lá disto, perante a necessidade de um atributo *birthDate*, teremos de converter as diferentes idades (*young*, *pesbyopic* e *pre-presbyopic*) em valores numéricos: assumamos que *young* tem até 30 anos, que *pre-presbyopic* varia entre 31 e 40 anos e que *presbyopic* tem mais de 40 anos, tal como descrito no portal Vision Science Academy[1].

age	prescription	astigmatic	tear_rate	lenses
young	myope	yes	normal	hard
young	myope	no	normal	soft
young	hypermetrope	yes	reduced	none
young	hypermetrope	no	normal	soft
young	hypermetrope	no	reduced	none
presbyopic	myope	yes	reduced	none
presbyopic	myope	yes	normal	hard
presbyopic	hypermetrope	yes	reduced	none
presbyopic	hypermetrope	yes	normal	none
presbyopic	hypermetrope	no	normal	soft
presbyopic	hypermetrope	no	reduced	none
pre-presbyopic	myope	yes	reduced	none
pre-presbyopic	myope	yes	normal	hard
pre-presbyopic	myope	no	normal	soft
pre-presbyopic	hypermetrope	yes	normal	none
pre-presbyopic	hypermetrope	no	normal	soft

Figura 1. Representação do dataset com a regra destacada

2.2. Desenvolvimento da base de dados

O modelo de dados reflete a atividade do "MedKnow" de forma coerente com a realidade médica. As entidades principais *patient*, *doctor* e *appointment* registam as consultas realizadas. As tabelas auxiliares *tear_rate* e *lenses* armazenam as classificações possíveis para a taxa lacrimal e o tipo de lente prescrita. A tabela *prescription* relaciona cada marcação médica (*appointment*) com a doença diagnosticada (*disease*). A tabela *age* define as faixas etárias utilizadas na decisão e será a classificadora.

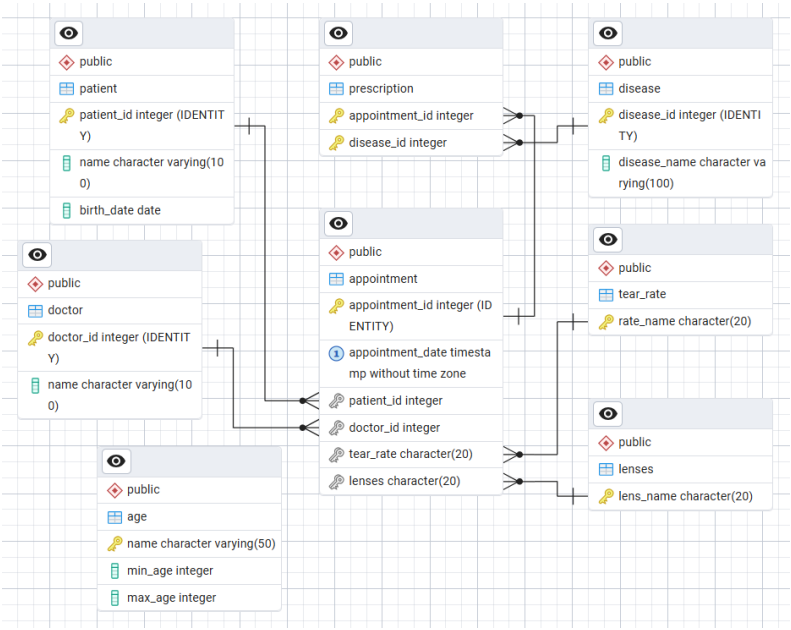


Figura 2. Diagrama ER correspondente à base de dados.

2.3. Inserção e visualização dos dados

Após a criação da base de dados e das tabelas necessárias, criámos o script 02_script_POPULATE_SCHEMA.txt (em anexo), para popular a base de dados, que será acionado por meio de um .bat executável.

	appointment_id [PK] integer	appointment_date timestamp without time zone	patient_id integer	doctor_id integer	tear_rate character (20)	lenses character (20)
1	1	2025-09-05 09:00:00	1	1	normal	soft
2	2	2025-05-23 09:30:00	2	1	reduced	hard
3	3	2024-08-15 10:00:00	3	2	normal	none
4	4	2024-01-28 12:00:00	4	2	reduced	soft
5	5	2019-05-18 15:30:00	5	1	normal	soft

Figura 3. Tabela *appointment* após ser povoada (exemplo).

	age text	prescription text	astigmatic text	tear_rate text	lenses text
1	discrete	discrete	discrete	discrete	discrete
2					class
3	young	myope	no	normal	soft
4	young	myope	no	normal	soft
5	presbyopic	hypermetrope	no	reduced	hard
6	presbyopic	hypermetrope	no	reduced	soft
7	pre-presbyopic	astigmatic	yes	normal	none

Figura 4. View *v1_dataset* após criação.

Em seguida, desenvolvemos o script 03_script_CREATE_VIEW.txt (em anexo), que possibilita a criação da view, onde foram criadas as views *v1_data* – contém os dados reais transformados – , *v1_class* – cria a linha que indica em que coluna é que fica a classe –, *v1_domain* – define os tipos de cada coluna – e *v1_dataset* – combina todas as views anteriores, e a função *getage* que ajuda ao mapeamento da idade de um paciente para uma idade pré-definida na tabela *age*. A função *getage* foi construída para receber um inteiro como argumento (data de nascimento do paciente) e filtra na tabela as linhas onde a idade fornecida está entre os valores de *min_age* e *max_age*, retornando o nome correspondente a essa idade. A função é chamada na view v1_data, para calcular a diferença de anos entre o ano atual e o ano de nascimento do paciente, convertendo-o para inteiro.

2.4. Exportação

Após a criação das views, segue-se a exportação dos dados formatados para o Orange, isto é, exportar os dados da view *v1_dataset* para um ficheiro que o Orange consiga importar. O script está em anexo, como 04_script_EXPORT_DATA.txt, e dele resulta a exportação de um ficheiro .tab para o o diretório do projeto, com os dados delimitados por tabulações e contendo os cabeçalhos das colunas.

2.5. Algoritmo 1R

O classificador 1 Rule (1R) é o algoritmo mais básico dentro da matéria de aprendizagem automática para prever a classe esperada da instância de uma dataset. O seu conceito é comparar a taxa de erro de todos os valores para cada atributo (coluna da tabela) da dataset e descobrir qual o atributo que tem menos taxa de erro para depois ser usado essa única feature para prever a classe da instância de uma dataset, é por isso que o algoritmo é chamado 1 Rule por usar um único atributo para prever classes, fazer com que todos os outros atributos de uma dataset sejam redundantes.

Para descobrir a taxa de erro para cada atributo, especialmente com valores discretos, de uma dataset é necessário calcular a partir da seguinte fórmula matemática:

Dados:

- D: dataset
- F: a feature (atributo)na dataset
- VF={v1,v2,...,vk}: todos os possívies valores de F
- C:variável de classe
- DF=vi⊆D: subconjunto de amostras onde a feature F=vi
- c∗(vi): most frequent class in subset DF=vi

Fórmula:

Taxa de erro do atributo:

For each value vi:

$$error(vi)=|DF=vi|-c\in Cmax(count(DF=vi,c))$$

Total error for feature F:

$$Error(F)=vi\in VF\sum error(vi)$$

Regra de classificação:

classe prevista = regra[instância[melhor_F]]

2.6. Algoritmo ID3 e Naïve Bayes

Os classificadores de induction tree e naive bayes são modelos que apresentam melhor precisão em comparação com o algoritmo 1 Rule que utiliza apenas uma característica da dataset.

O método Naive Bayes estima probabilidades assumindo que existe independência condicional entre os atributos, ou seja, tal como o nome diz, é usado o teorema bayes para prever a classe:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$$P(Class|Features) = \frac{P(Features|Class) \times P(Class)}{P(Features)}$$

Ele é mais eficiente e robusto em pequenos conjuntos de dados, mas normalmente o seu desempenho é pior do que outros classificadores mais avançados, especialmente quando a dataset tem muitas instâncias para classificar independentemente as suas características ou os seus atributos não estão bem representadas.

O classificador induction tree é um modelo mais avançado do que os outros dois modelos referidos, sendo o que usa um modelo do tipo árvore de grafos. Este modelo foi usado no projeto a framework Orange que utiliza o algoritmo C4.5 que é um extensor do algoritmo ID3. O modelo começa pelo um nó de raiz que contém a dataset toda, em seguida é dividida em dois nós de subdados da dataset. Isto é feito recursivamente para cada divisão de nós de dados. A divisão de nós é terminada quando não existe valor para a previsão de classes. Induction tree tem tendência a overfitting, para não acontecer tal coisa, é necessário remover nós que não têm valor para previsão ou até adicionar um valor máximo de profundidade de divisão de nós. No final, com esta complexidade induction tree é o melhor modelo para classificação entre os modelos referidos, mas pelo um preço de um custo computacional.

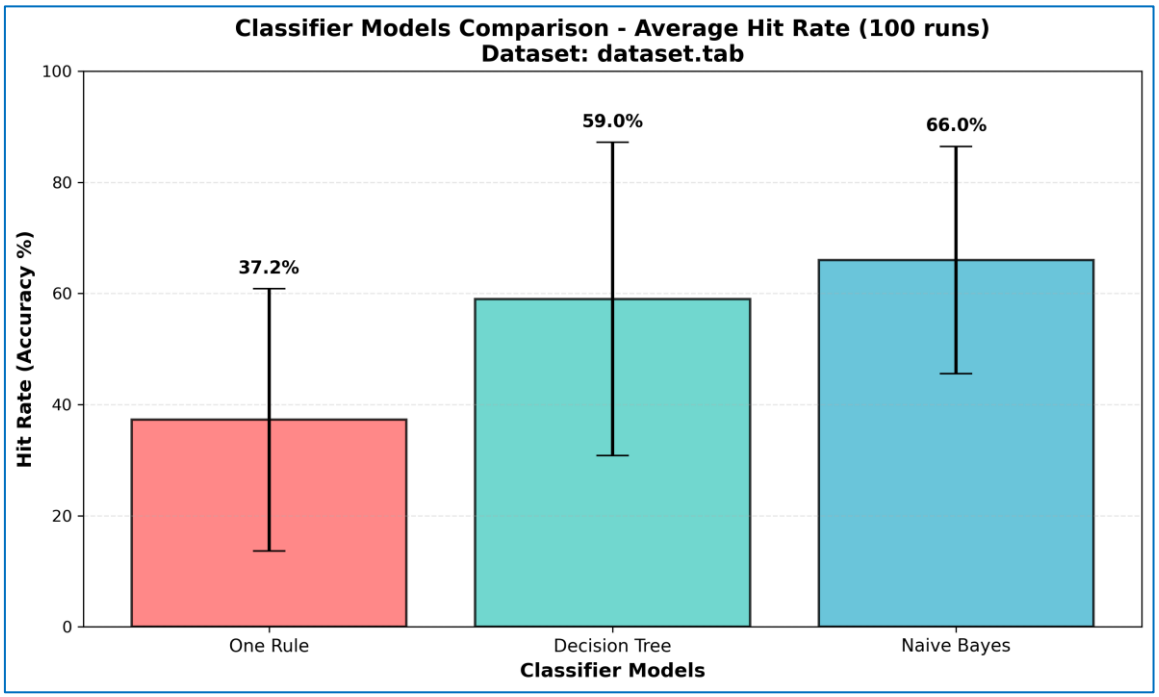
O classificador induction tree é um modelo que utiliza uma estrutura em forma de árvore para realizar classificações. O processo começa com um nó raiz, que contém todo o conjunto de dados, e em seguida divide-o em subconjuntos com base nos valores das variáveis de entrada. Essa divisão ocorre recursivamente, criando nós filhos até que se atinja uma condição de paragem — por exemplo, quando todos os exemplos de um nó pertencem à mesma classe ou quando não há ganho informativo em novas divisões. As árvores de decisão tendem a sofrer de overfitting, especialmente quando crescem demasiado. Para evitar isso, podem aplicar-se técnicas como pruning (remover nós pouco relevantes) ou limitar a profundidade máxima da árvore. Apesar do seu custo computacional mais elevado, este modelo é geralmente mais flexível e interpretável do que outros classificadores, podendo alcançar bom desempenho dependendo do problema, mas é dependente de uma grande quantidade de instâncias numa dataset.

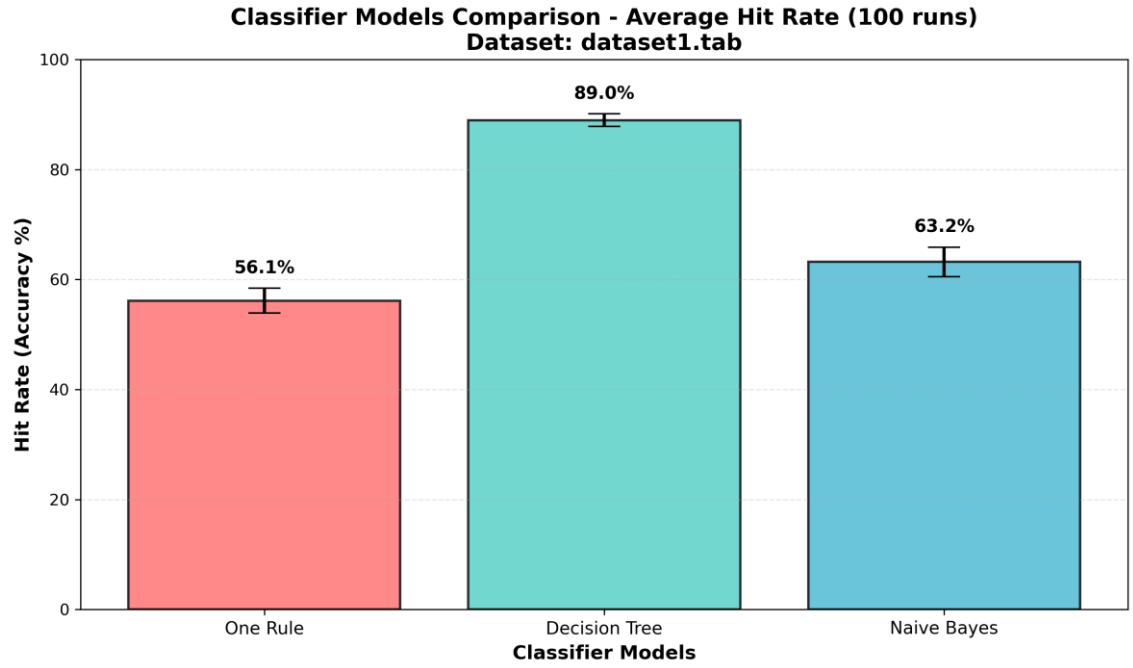
2.7 Avaliações métricas

Foi criado resultados experimentais em que compara os três classificadores usados no projeto a partir da taxa de acerto. Nesta comparação foram usadas duas datasets com características do ficheiro d01_lenses.xls: dataset.tab e dataset1.tab. O ficheiro dataset.tab tem as mesmas instâncias e atributos que o ficheiro d01_lenses.xls tem, em que contém 4 atributos (age, prescription, astigmatic e tear_rate) e 16 instâncias. E o ficheiro dataset1.tab tem as mesmas características e

classes que o ficheiro d01_lenses.xls tem, mas foi gerado uma abundância de instâncias adicionais para obter uma dataset de grandes dimensões, a dataset contém 2050 instâncias.

Usando o script: compare_models.py, foi gerado gráficos que compara os classificadores 1 Rule, induction tree e naive bayes pela taxa de acerto ao utilizar as duas datasets na divisão de dataset de teste. (Existe um ficheiro README que explica como utilizar o script de avaliação métrica e o script em python foi usado inteligência artificial a partir da ferramenta copilot). Nos seguintes dois gráficos estão apresentados as comparações entre os modelos ao executar N vezes a mesma dataset e fazer a média da taxa de acerto de todas as execuções de teste dos modelos. Neste caso ambos os gráficos foram executados 100 vezes nas duas datasets:





No primeiro gráfico, é avaliado os modelos usando a dataset: dataset.tab que contém 16 instâncias verifica-se que o classificador naive bayes tem melhor desempenho, isto é porque utiliza a probilidade condicional independente para estimar a classe o que consegue generalizar a previsão de classes numa dataset com poucas amostras, ao contrário do do induction tree, o classificador é prejudicado por overfitting por não ter uma grande quantidade de amostras para memorizar melhor os dados que são treinados. Por último o 1 Rule é o que tem pior desempenho por só usar uma única característica para prever classes, descartando todas as outras features na previsão.

No segundo gráfico, é usado a dataset: dataset1.tab que contém 2050 instâncias que usa as mesmas características e classes da dataset referida anteriormente. Como é visto, induction tree é o modelo com melhor desempenho por ser treinado numa dataset uma grande quantidade de instâncias. A taxa de acerto no classificador naive bayes é pior que o anterior por ser usado uma dataset grande e com isto as características começam a ter uma correlação o que começa a perder a independência entre as features, daí ter pior desempenho. Por fim, 1 Rule continua a ter pior resultado do que os outros modelos, mas melhorou do que no outro dataset, pois é visto que 1 Rule depende da dimensão da dataset, quanto maior a dataset melhor o desempenho do algoritmo 1 Rule.

3. Conclusão

Após ter gerado resultados experimentais, foi concluído o desempenho de cada modelo. Contudo, não existe um modelo geralmente melhor que o outro. Para os três modelos que foram utilizados neste projeto, o seu desempenho depende muito dos dados da dataset. Pois, foi visto que o uso do treino de uma dataset com poucas amostras traz a favor o classificador naive bayes devido ao uso estimação a partir da probabilidade indenpendete condicional, mas se foi utilizado o treino de uma dataset de grandes dimensões o modelo induction tree concretiza melhor desempenho por memorizar com mais parâmetros. Em relação ao 1 Rule é pior dos classificadores referidos por apenas ser usado a melhor característica com menos taxa de erro para classificar uma amostra o que tira pouco proveito de todos os outros atributos de uma dataset e também se viu que quanto maior o númeor de instãncias de uma dataset melhor o desempenho do 1 Rule.

Referências:

https://deepai.org/machine-learning-glossary-and-terms/tree-induction-algorithm

https://chatgpt.com/share/69091756-21bc-8007-ab7e-b898bce1fdd8

https://chatgpt.com/share/69124dc9-5804-8007-913e-a67a856629a6

https://orange.readthedocs.io/en/latest/reference/rst/Orange.classification.tree.html

https://www.tandfonline.com/doi/pdf/10.1080/08839514.2018.1447479

https://www.geeksforgeeks.org/machine-learning/naive-bayes-classifiers/