Instituto Superior de Engenharia de Lisboa

Departamento de Engenharia Eletrónica e Telecomunicações e de Computadores (DEETC)

Mestrado em Engenharia Informática e de Computadores

FINAL PROJECT - A1

Aprendizagem e Mineração de Dados (AMD)

1º Semestre – 2025/2026



Autores:

Florin Sofinet (A46608)
Diogo Guerra (A49149)
Nuno Silva (A53976)

1 de dezembro de 2025

Conteúdo

1 Introdução **2**

2 Análise do dataset e da descrição **2**
2.1 Origem e contexto do dataset 2
2.2 Objetivo da classificação 2
2.3 Características do dataset 2
2.4 Distribuição das classes 2
2.5 Atributos do dataset 3

3 Transformação para formato .tab (Orange) **3**
3.1 Método de transformação 4
3.2 Formato .tab do Orange 4
3.3 Configuração da variável de classe 4
3.4 Ficheiro resultante 5

4 Aplicação do classificador 1R **5**
4.1 Implementação do algoritmo 1R 5
4.2 Execução e resultados 5
4.3 Atributo selecionado: odor 6
4.4 Taxa de erro 6
4.5 Regras geradas 6
4.6 Análise detalhada dos resultados 6
4.7 Interpretação das regras 7
4.8 Conclusões do exercício 1R 7

5 Exploração em Orange Data Mining **7**
5.1 Número total de instâncias 8
5.2 Número de instâncias de cada classe 8
5.3 Classificador Tree 9
5.4 Classificador Random Forest 9
5.5 Previsões 10

6 Conclusão **10**

1. Introdução

Este laboratório tem como objetivo explorar métodos de avaliação de modelos de Machine Learning, combinando capacidades programáticas de Python com ferramentas de outras bibliotecas e do ambiente do Orange Data Mining.

Ao longo do trabalho, serão analisadas diversas técnicas de divisão de dados, métodos de amostragem, bootstrap, métricas de desempenho e construção de classificadores.

2. Análise do dataset e da descrição

O primeiro exercício consistiu na análise detalhada do ficheiro de dados original (`dataset_long_name_ORI` e da respetiva descrição (`dataset_description.txt`), identificando o significado de cada atributo, o objetivo da classificação, o número de instâncias, eventuais valores em falta e a distribuição das classes.

2.1. Origem e contexto do dataset

O dataset utilizado provém do *UCI Machine Learning Repository* e contém descrições de amostras correspondentes a 23 espécies de cogumelos com lamelas das famílias Agaricus e Lepiota. Os dados foram extraídos do *Audubon Society Field Guide to North American Mushrooms* (1981).

2.2. Objetivo da classificação

Cada amostra de cogumelo é classificada em uma das seguintes categorias:

- **Edible** (comestível) – cogumelos seguros para consumo
- **Poisonous** (venenoso) – cogumelos tóxicos ou de comestibilidade desconhecida

2.3. Características do dataset

O dataset apresenta as seguintes características principais:

- **Número de instâncias:** 8416 amostras
- **Número de atributos:** 22 atributos nominais (categóricos)
- **Atributo de classe:** `class` (EDIBLE ou POISONOUS)
- **Valores em falta:** 2480 valores ausentes (representados por "?"), todos no atributo #11 (`stalk-root`)

2.4. Distribuição das classes

A distribuição das classes no dataset é relativamente equilibrada:

- **Edible:** 4488 instâncias (53.33%)
- **Poisonous:** 3928 instâncias (46.67%)

Através de ferramentas de análise no Visual Studio Code, confirmou-se que o dataset contém exatamente 8416 instâncias (excluindo o cabeçalho), das quais 4488 são da classe *edible* e 3928 da classe *poisonous*.

2.5. Atributos do dataset

O dataset contém 22 atributos descritivos, todos nominais:

1. `cap-shape` – forma do chapéu (bell, conical, convex, flat, knobbed, sunken)
2. `cap-surface` – superfície do chapéu (fibrous, grooves, scaly, smooth)
3. `cap-color` – cor do chapéu (brown, buff, cinnamon, gray, green, pink, purple, red, white, yellow)
4. `bruises` – presença de hematomas (bruises, no)
5. `odor` – odor (almond, anise, creosote, fishy, foul, musty, none, pungent, spicy)
6. `gill-attachment` – tipo de fixação das lamelas (attached, free)
7. `gill-spacing` – espaçamento das lamelas (close, crowded)
8. `gill-size` – tamanho das lamelas (broad, narrow)
9. `gill-color` – cor das lamelas (10 valores possíveis)
10. `stalk-shape` – forma do caule (enlarging, tapering)
11. `stalk-root` – raiz do caule (bulbous, club, equal, rooted, missing)
12. `stalk-surface-above-ring` – superfície do caule acima do anel
13. `stalk-surface-below-ring` – superfície do caule abaixo do anel
14. `stalk-color-above-ring` – cor do caule acima do anel
15. `stalk-color-below-ring` – cor do caule abaixo do anel
16. `veil-type` – tipo de véu (partial)
17. `veil-color` – cor do véu (brown, orange, white, yellow)
18. `ring-number` – número de anéis (none, one, two)
19. `ring-type` – tipo de anel (8 valores possíveis)
20. `spore-print-color` – cor da impressão dos esporos (9 valores possíveis)
21. `population` – tipo de população (abundant, clustered, numerous, scattered, several, solitary)
22. `habitat` – habitat (grasses, leaves, meadows, paths, urban, waste, woods)

3. Transformação para formato .tab (Orange)

O segundo exercício consistiu na transformação do dataset original (`dataset_long_name_ORIGINAL.csv`) para o formato `.tab`, que é o formato nativo utilizado pelo Orange Data Mining. Este formato permite uma melhor integração com as ferramentas de análise e visualização do Orange.

3.1. Método de transformação

Para realizar a conversão, utilizou-se um script Python simples (`dataset_converter.py`) que aproveita a biblioteca Orange para carregar o ficheiro CSV e convertê-lo automaticamente para o formato `.tab`:

```
import Orange

# Load CSV
data = Orange.data.Table("dataset_long_name_ORIGINAL.csv")

# Save as TAB
data.save("dataset_long_name_CONVERTED.tab")
```

Este método é preferível à conversão manual porque:

- Preserva corretamente os tipos de dados dos atributos
- Mantém a estrutura e metadados necessários para o Orange
- Garante compatibilidade total com o ambiente Orange Data Mining
- É reprodutível e automatizável

3.2. Formato .tab do Orange

O formato `.tab` do Orange é uma variante do formato TSV (Tab-Separated Values) que inclui três linhas de cabeçalho:

1. **Linha 1:** Nomes dos atributos
2. **Linha 2:** Tipos/flags dos atributos (ex: discrete, continuous, class, meta)
3. **Linha 3:** Valores possíveis para atributos discretos
4. **Linhas seguintes:** Dados das instâncias

3.3. Configuração da variável de classe

Durante o processamento do dataset convertido, foi necessário ajustar a configuração para garantir que o atributo `class` fosse corretamente identificado como a variável de classe (target). Isto foi feito programaticamente no ficheiro `classifier_handler.py`:

```
# If 'class' is not the class variable, set it manually
if self.data.domain.class_var is None:
    class_attr = None
    for attr in self.data.domain.attributes:
        if attr.name == 'class':
            class_attr = attr
            break

    if class_attr:
        new_attrs = [attr for attr in self.data.domain.attributes
```

```
                if attr.name != 'class']
new_domain = Orange.data.Domain(new_attrs, class_attr)
self.data = self.data.transform(new_domain)
```

Esta configuração garante que o atributo `class` seja tratado como a variável dependente nas análises subsequentes, permitindo que os algoritmos de classificação funcionem corretamente.

3.4. Ficheiro resultante

O ficheiro resultante (`dataset_long_name_CONVERTED.tab`) mantém todas as 8416 instâncias e os 22 atributos originais, com o atributo `class` corretamente configurado como variável de classe. Este ficheiro foi utilizado como base para os exercícios seguintes, nomeadamente para a aplicação do algoritmo 1R e para as análises no Orange Data Mining.

4. Aplicação do classificador 1R

O terceiro exercício consistiu na aplicação do algoritmo 1R (*One Rule*) ao dataset de cogumelos. O algoritmo 1R é um classificador simples mas eficaz que seleciona o atributo único que melhor classifica os dados, criando regras baseadas nos valores desse atributo.

4.1. Implementação do algoritmo 1R

O algoritmo 1R foi implementado em Python utilizando a biblioteca Orange. A implementação encontra-se no ficheiro `one_rule.py` e segue os seguintes passos:

1. Para cada atributo discreto no dataset:
    - Para cada valor possível do atributo, identifica a classe mais frequente
    - Calcula o número de erros (instâncias que não pertencem à classe mais frequente)
2. Seleciona o atributo com o menor número total de erros
3. Retorna o atributo selecionado, a regra correspondente e a taxa de erro

4.2. Execução e resultados

A aplicação do algoritmo 1R foi realizada através do script `classifier_handler.py`, que:

- Carrega o dataset convertido (`dataset_long_name_CONVERTED.tab`)
- Divide os dados em conjunto de treino (80%) e teste (20%)
- Aplica o algoritmo 1R ao conjunto de treino
- Gera estatísticas detalhadas para cada combinação (atributo, valor, classe)

O algoritmo foi executado com sucesso, gerando o ficheiro `oneR_OUTPUT.txt` com o formato especificado.

4.3. Atributo selecionado: odor

O algoritmo 1R selecionou o atributo **odor** (odor do cogumelo) como o melhor preditor único para a classificação. Este resultado é altamente significativo e intuitivo do ponto de vista biológico, uma vez que o odor é frequentemente um indicador importante da comestibilidade de cogumelos.

4.4. Taxa de erro

A taxa de erro obtida foi de apenas **0.0143** (1.43%), o que demonstra que o atributo `odor` sozinho é capaz de classificar corretamente 98.57% das instâncias do conjunto de treino. Este resultado excepcionalmente bom sugere que o odor é um preditor extremamente forte para este dataset.

4.5. Regras geradas

As regras geradas pelo algoritmo 1R para o atributo `odor` são apresentadas no ficheiro `oneR_OUTPUT.txt` no formato especificado:

```
(attr, valueAttr, valueTarget) : (error, total)
```

onde:

- `attr` – nome do atributo selecionado (odor)
- `valueAttr` – cada valor possível do atributo odor
- `valueTarget` – cada classe (EDIBLE ou POISONOUS)
- `error` – número de classificações incorretas para essa combinação
- `total` – número total de instâncias para essa combinação

4.6. Análise detalhada dos resultados

Os resultados completos obtidos do ficheiro `oneR_OUTPUT.txt` são:

```
Selected attribute: odor
Error rate: 0.0143

(odor, ALMOND, EDIBLE) : (0, 308)
(odor, ANISE, EDIBLE) : (0, 304)
(odor, CREOSOTE, POISONOUS) : (0, 153)
(odor, FISHY, POISONOUS) : (0, 472)
(odor, FOUL, POISONOUS) : (0, 1724)
(odor, MUSTY, POISONOUS) : (0, 35)
(odor, NONE, EDIBLE) : (0, 2957)
(odor, NONE, POISONOUS) : (96, 96)
(odor, PUNGENT, POISONOUS) : (0, 218)
(odor, SPICY, POISONOUS) : (0, 465)
```

4.7. Interpretação das regras

A análise dos resultados revela padrões claros:

- **Odores associados a cogumelos comestíveis:**
  - ALMOND (amêndoa): 308 instâncias, todas EDIBLE (0 erros)
  - ANISE (anis): 304 instâncias, todas EDIBLE (0 erros)
  - NONE (sem odor): 2957 instâncias EDIBLE, classificadas corretamente
- **Odores associados a cogumelos venenosos:**
  - CREOSOTE: 153 instâncias, todas POISONOUS (0 erros)
  - FISHY (peixe): 472 instâncias, todas POISONOUS (0 erros)
  - FOUL (fétido): 1724 instâncias, todas POISONOUS (0 erros)
  - MUSTY (mofo): 35 instâncias, todas POISONOUS (0 erros)
  - PUNGENT (pungente): 218 instâncias, todas POISONOUS (0 erros)
  - SPICY (picante): 465 instâncias, todas POISONOUS (0 erros)
- **Única fonte de erros:**
  - NONE (sem odor) + POISONOUS: 96 instâncias mal classificadas
  - Estes cogumelos venenosos sem odor característico foram incorretamente classificados como EDIBLE pela regra, uma vez que a maioria dos cogumelos sem odor (2957) são comestíveis

4.8. Conclusões do exercício 1R

O algoritmo 1R demonstrou que:

1. O atributo `odor` é um preditor excepcionalmente forte para a classificação de cogumelos
2. Cogumelos com odores como ALMOND ou ANISE são consistentemente comestíveis
3. Cogumelos com odores desagradáveis (FOUL, FISHY, MUSTY, PUNGENT, SPICY) são consistentemente venenosos
4. A única ambiguidade significativa ocorre com cogumelos sem odor (NONE), onde existe uma pequena minoria de espécimes venenosos (96 em 3053)
5. A taxa de erro extremamente baixa (1.43%) confirma a eficácia do odor como característica discriminativa

5. Exploração em Orange Data Mining

No último ponto utiliza-se o Orange Data Mining para construir um fluxo visual que permita inspeccionar o dataset, contar o número total de instâncias, analisar a distribuição das classes, treinar classificadores do tipo Tree e Random Forest, e gerar previsões com ambos.

5.1. Número total de instâncias

O dataset fornecido contém 8416 instâncias (ocorrências) das características observadas, tal como se pode ver na Figura 1.

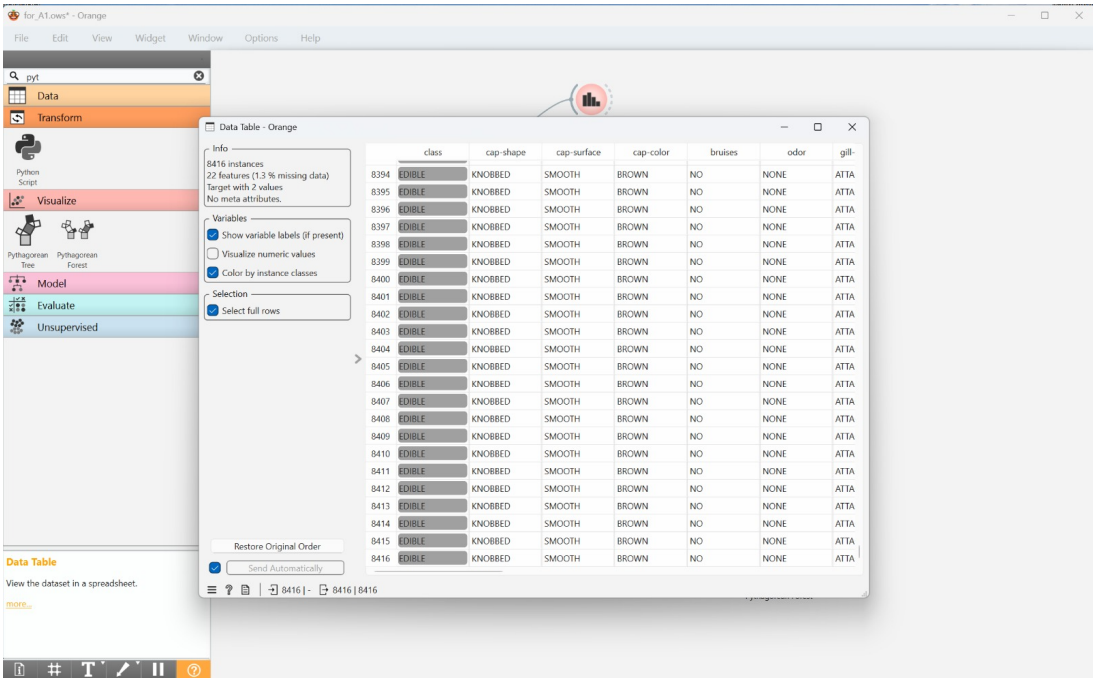


Figura 1: Data table of dataset.

5.2. Número de instâncias de cada classe

O FungiDataset tem uma distribuição com 4488 instâncias classificadas como EDIBLE e 3928 instâncias classificadas como POISONOUS, tal como se pode ver na figura abaixo.

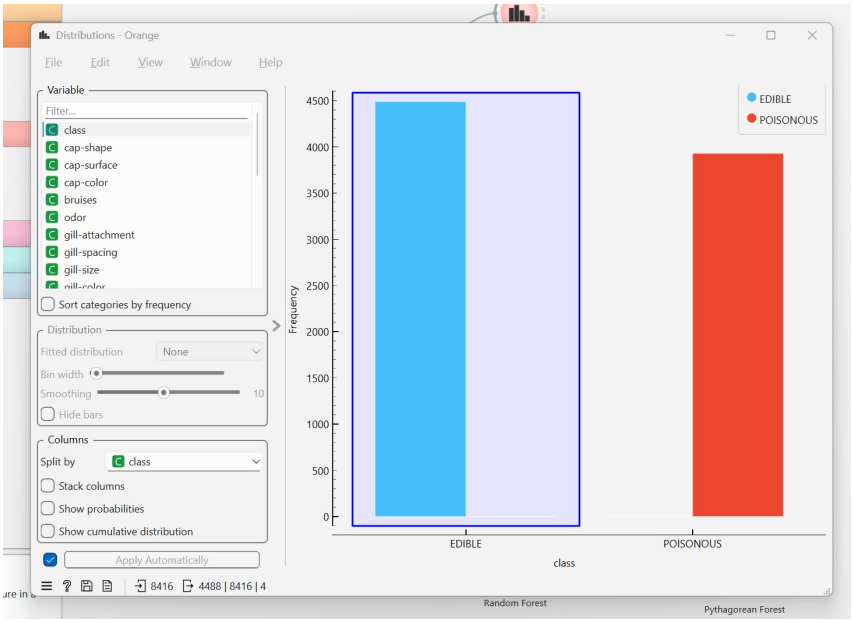


Figura 2: Distribution of classes.

5.3. Classificador Tree

A Figura 3 mostra o resultado da classificação TREE utilizando Orange. Pode observar-se que escolheu o mesmo parâmetro que o 1R, identificando corretamente todos os cogumelos venenosos e perdendo apenas 2,5% dos comestíveis (falsos negativos). A árvore de decisão separa facilmente os cogumelos porque o atributo odor é um preditor forte.

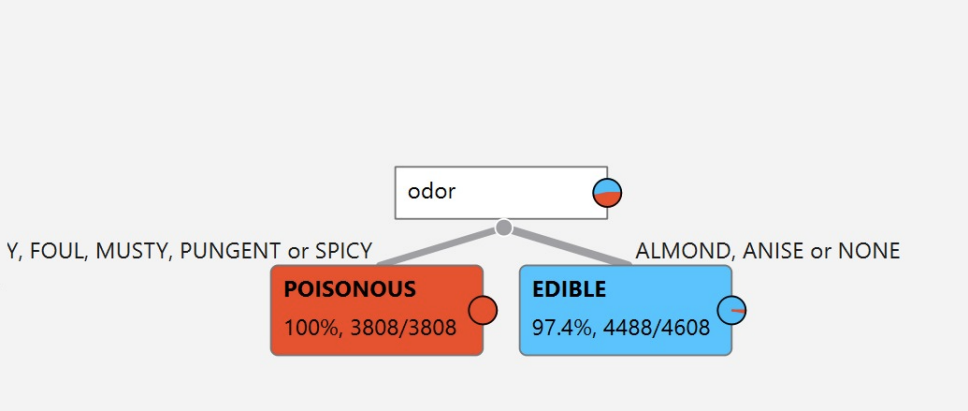


Figura 3: Result of Tree classification.

5.4. Classificador Random Forest

O classificador Random Forest demonstra eficácia absoluta ao classificar corretamente todas as ocorrências nas suas respectivas classes. A Figura 4 ilustra perfeitamente a matriz de confusão na diagonal. Random Forest agrega múltiplas árvores de decisão para previsões mais estáveis.

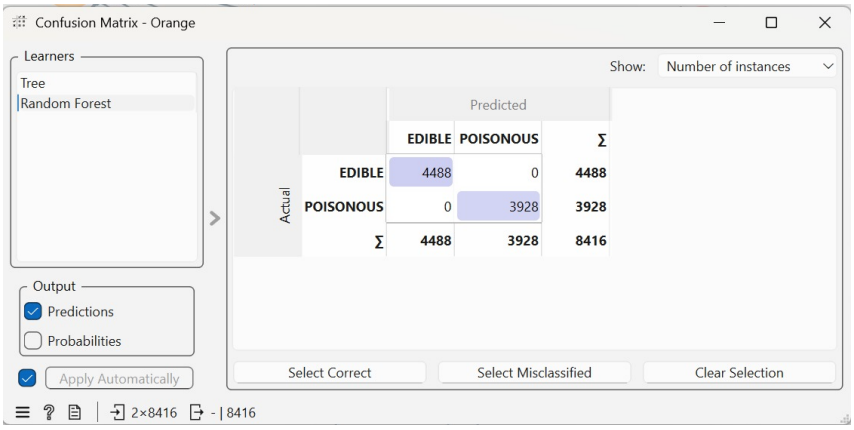


Figura 4: Confusion Matrix of Random Forest.

O melhor desempenho deste classificador em relação ao anterior deve-se à sua melhor distribuição de dados de treino e teste, bem como à sua dependência de múltiplas árvores de decisão. A figura seguinte mostra as árvores geradas.

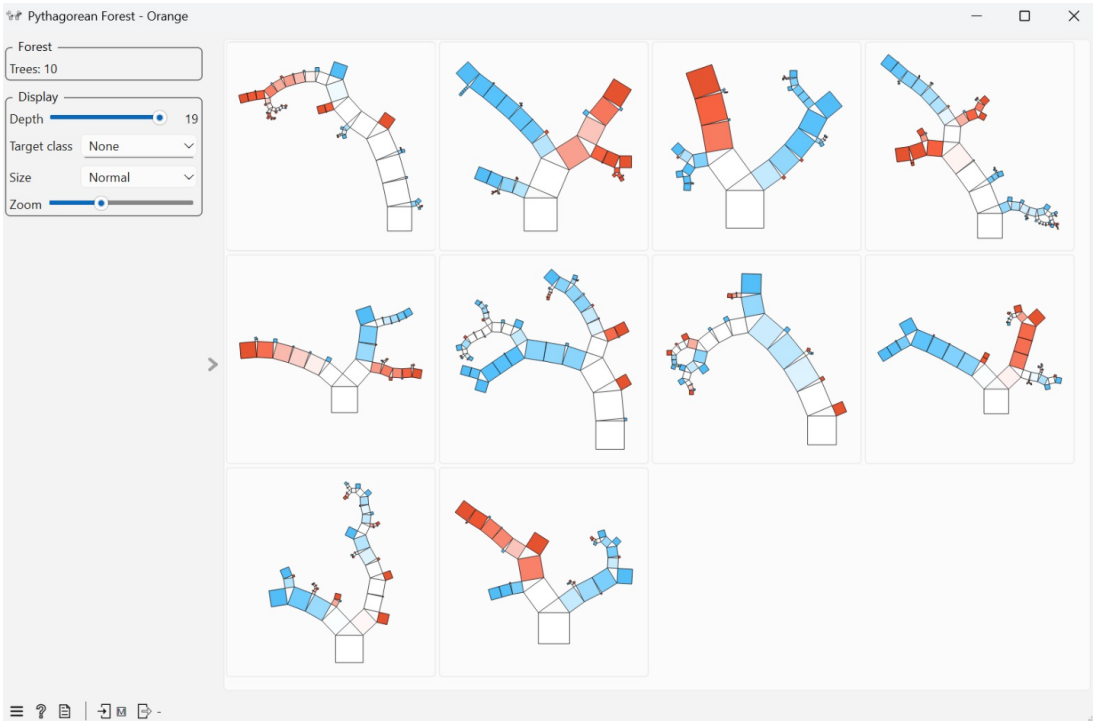


Figura 5: Pythagorean Forest map.

5.5. Previsões

Os classificadores Random Forest (Figura 4) e Tree (Figura 6) são comparados e, como mencionado anteriormente, RF tem uma pontuação perfeita, identificando corretamente todas as classes, apesar do pequeno desvio da árvore

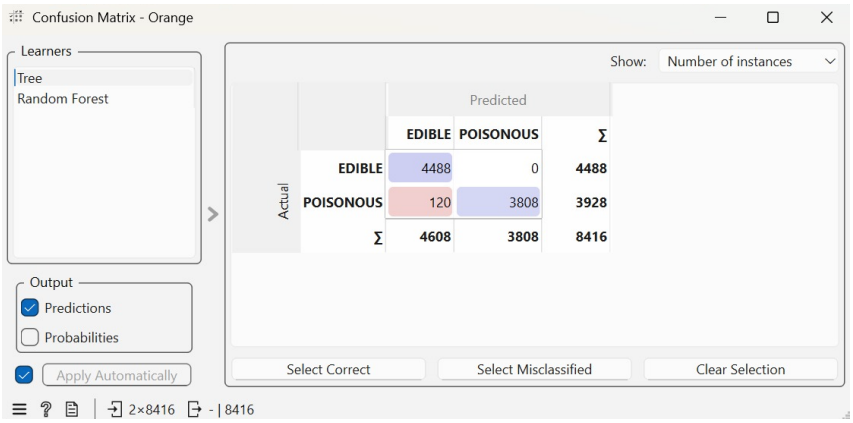


Figura 6: Confusion Matrix of Tree.

6. Conclusão

A realização deste laboratório permitiu aplicar de forma integrada várias competências desenvolvidas ao longo da unidade curricular: análise de datasets reais, preparação e transformação de dados, implementação e utilização de classificadores simples como o 1R, e exploração de modelos mais avançados em Orange Data Mining.

A utilização combinada de código e ferramentas visuais evidencia a complementaridade entre abordagens programáticas e ambientes de data mining interativos.

O dataset de cogumelos contém 8416 instâncias. O atributo odor domina a classificação. Random Forest confirma a robustez das previsões. Ambos obtiveram uma pontuação próxima da perfeição, com Random Forest a ter uma previsão ligeiramente mais precisa.