Instituto Superior de Engenharia de Lisboa (ISEL)
Departamento de Engenharia Eletrónica e de
Telecomunicações e Computadores (DEETC)

MEIM
Mestrado em Engenharia Informática e Multimédia
Unidade Curricular de Aprendizagem e Mineração de Dados

Projeto Final B



Rui Loureiro (48054)
Jairo Ramos (48623)

Docente

Professor Paulo Trigo

30 de dezembro de 2024

Índice

1 Introdução **6**

2 *Análise do Dataset* **7**

3 *Formulação do Problema market-basket analysis* **8**

4 *Distribuição dos Dados* **8**

5 *Gerar um Sub-Conjunto* **8**

6 *Propostas e Decisões* **9**
6.1 which few products should be kept together in a Web page? . . . 9
6.2 which products are rarely visited but often visited together? . . . 10
6.3 which products are the most visited? 11

7 *Orange DM Análise* **12**

8 *Implementação do código automático* **14**

9 Conclusões **16**

Lista de Figuras

1 Dataset Info 7
2 Melhor conjunto de regras. 9
3 Dados do *Plot* 2 10
4 Produtos pouco acedidos mas sempre em conjunto. 10
5 Dados do *Plot* 4 11
6 Produtos mais visitados 12
7 Dados do *Plot* 6 12
8 Conjunto de Itens 13
9 Regras de Associação 14
10 *Plot* das regras 14
11 Diretoria automatico 15

Lista de Tabelas

Lista de Acrónimos

IP Internet Protocol. 8

1 Introdução

Este relatório apresenta uma análise detalhada do conjunto de dados fornecido pela plataforma de comércio eletrónico "We-Commerce", contendo informações sobre acessos dos utilizadores ao sistema. O dataset analisado consiste em 415 586 registos, cada um representando uma ocorrência de interação de utilizadores com a plataforma. Estes registos incluem 14 atributos de diferentes tipos: 3 categóricos, 2 numéricos e 9 textuais (metadados). Apesar da grande dimensão do conjunto de dados, aproximadamente 0,8% dos registos apresentam valores ausentes em algumas colunas.

O objetivo principal desta análise é extrair informações úteis a partir dos dados, identificar padrões de comportamento dos utilizadores e propor recomendações de organização para a plataforma, com base em técnicas de mineração de dados como a análise de regras de associação (*market-basket analysis*). Este relatório está estruturado para abordar desde a compreensão e descrição inicial dos dados até a aplicação prática de ferramentas analíticas para gerar insights significativos e recomendações estratégicas.

Além disso, inclui uma visão geral da distribuição dos dados, a criação de sub-conjuntos relevantes para reduzir a complexidade computacional e as decisões tomadas com base nos resultados obtidos. Por fim, são apresentadas as recomendações derivadas, incluindo propostas de agrupamento de produtos frequentemente visitados em conjunto e a identificação de itens menos acessados, mas com alta probabilidade de associação.

2 *Análise do Dataset*

Este conjunto de dados fornecido contém 415 586 registos (tuplos) de ocorrências de acesso dos utilizadores duma plataforma de comércio online, com 14 características (colunas) onde 3 são categorias, 2 numéricas e 9 de texto (meta dados). O conjunto possui cerca de 16 335 tuplos com colunas de dados em falta, cerca 0.8% dos dados totais.

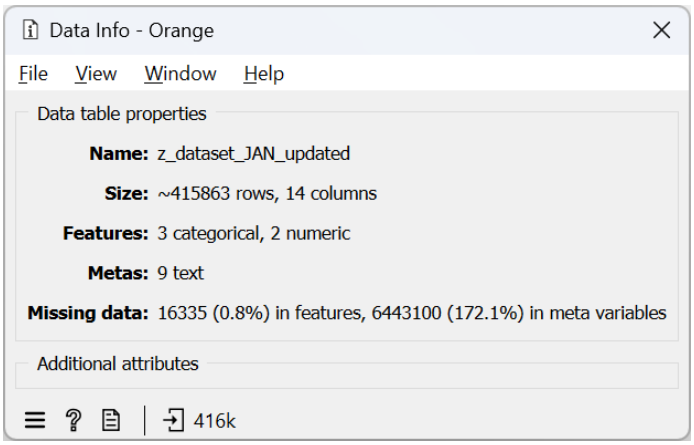


Figura 1: Dataset Info

A seguir está uma lista das colunas presente no conjunto de dados e a descrição dos seus significados e importância.

1. **tracking_record_id**: coluna auto-incrementada que identifica cada acesso feito na plataforma por um utilizador, forte candidata ou possível chave primária da tabela "*Track*".
2. **date_time**: regista o *timestamp* do momento que o utilizador acedeu a página online.
3. **user_gui**: identificador único dos utilizadores registado no site.
4. **campaign_id**: identificador da empresa fornecedora e campanha acedida pelo utilizador durante a navegação.
5. **product_gui**: coluna feita para um identificador único do produto, no entanto também está a fazer o registo de outros dados não relacionados, por exemplo, categorias e descrições.
6. **company**: identifica o nome do fornecedor do produto visitado no site.
7. **link**: registo do *link* carregado pelo utilizador.
8. **tracking_id**: faz o registo do tipo de codificação (enconde) usado pelo navegador do utilizador.

9. **meio**: registo da fonte (natureza) de onde o acesso teve origem.

10. **ip**: registo do Internet Protocol (IP) dinâmico do utilizador que fez acesso ao site.

11. **browser**: identifica o tipo de software cliente usado no acesso a plataforma e-commerce.

12. **session_id**: nome da sessão criada pelo acesso do utilizador ao site, mantendo o estado da sua visita.

13. **referer**: indicador da página web que direcionou o utilizador para a página registada.

14. **cookie_id**: identificador único do *coockie* instalado no navegador do utilizador.

3 *Formulação do Problema market-basket analysis*

Um problema do tipo análise de cesto do supermercado (*market-basket analysis*) dá-se quando é possível encontrar grupos de itens com tendência a aparecer em uma transação, ou seja, no registo duma ocorrência.

Neste problema em questão, os item são identificados pelo *product_id* e a transação pode ser o *user_gui* ou *session_id*, como o identificador de *user* apenas aparece para utilizadores registados, o indicador de sessão tem maior cobertura.

4 *Distribuição dos Dados*

A distribuição de dados foi feita como indicado no enunciado e testado com o o ficheiro de exemplo (*z01_aggregatedView.txt*) fornecido pelo docente. O trabalho foi feito usando os *scripts* de suporte fornecidos nos laboratório 7.

5 *Gerar um Sub-Conjunto*

Foi construida a *view v_relevant_events* com base nas indicações do enunciado e o que foi praticado no laboratório de suporte ao projeto.

Criou-se também uma última vista (*clean_data*) para remover dados incongruente da lista de tuplos. Ela remove uma sequência de registos com valores que não são relevantes a processo e que poderiam afetar o resultado.

```
    'open', 'display.category*homepage', '/checkout/cart/', '/customer/account/login/',
'/customer/account/forgotpassword/', '/customer/account/index/', '/customer/account/',
'home', '/onestepcheckout/', 'intro*fbpage*link1', '/customer/account/logoutSuccess/',
```

```
'/lon-customer-support', '/ljv-customer-support', '/?newsletter', '/lon-contacts',
'/stx-customer-support', '/customer/account/create/', '/sam-contacts',
'/sam-brand', '/lon-legal', '/ljv-about-us', '/sales/order/history/',
'/sam-customer-support', 'paginacontactos', '/gio-contacts', '/lon_es-customer-support',
'/customer/account/edit/', '/customer/address/index/', '/lon_en-customer-support',
'/customer/address/edit/', '/customer/account/index/?___store=lon'
```

6 *Propostas e Decisões*

O ficheiro gerado (*.basket*) para ser trabalhado foi construido com a característica do *cookie_ id* para a transação e o *product_ gui* para os itens.

Na pesquisa de regras de associação o ficheiro regras que tem um suporte máximo chegando até 140 e também regras com uma confiança de até 1.0 (100%). O conjunto de tuplos finais pelo ficheiro foram 1 772.

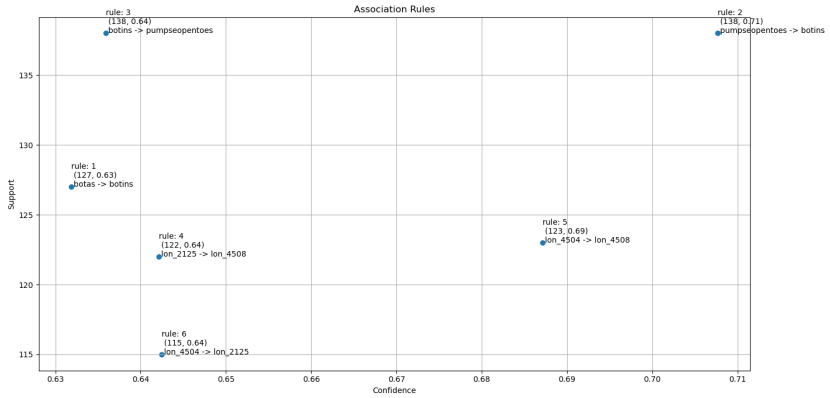


Figura 2: Melhor conjunto de regras.

A Figura 2 mostra o resultado da pesquisa do espaço de regras filtrado para um suporte mínimo de 115 e uma confiança mínima de 62%. Na legenda em cada ponto está o número da regra, o suporte e confiança entre parênteses e os objetos *LHS e RHS*.

6.1 which few products should be kept together in a Web page?

Através dos dados no *plot* da Figura 2 ou como a Figura 3 é possível responder a primeira pergunta.

```
Decoded setOf-rules:
rules.len: 6
(supp, conf): LHS -> RHS
rule: 1 - (127, 0.6318): ['botas'] -> ['botins']
rule: 2 - (138, 0.7077): ['pumpseopentoes'] -> ['botins']
rule: 3 - (138, 0.6359): ['botins'] -> ['pumpseopentoes']
rule: 4 - (122, 0.6421): ['lon_2125'] -> ['lon_4508']
rule: 5 - (123, 0.6872): ['lon_4504'] -> ['lon_4508']
rule: 6 - (115, 0.6425): ['lon_4504'] -> ['lon_2125']
```

Figura 3: Dados do *Plot* 2

A regra nº 2 na figura anterior possui o maior suporte no conjuto de regras assim como a maior confiança de 71%, que indica que o utilizador que acede a página *pumpseopentoes* irá adquirir os *botins* ou botas fazendo uma dedução dos dados que foram disponibilizados. A regra nº 3 é a simétrica da nº 2 indicando a relação estes estes dois itens.

As regras 4 a 6 apresentam um código que acreditamos ser o nome do fornecedor com o número de produto, este itens também estão relacionados entre si e podem também ser associados.

6.2 which products are rarely visited but often visited together?

Na Figura 4 está o resultado da procura de regras com os parâmetros suporte a 60 e confiança a 92%, gerando um conjunto de 51 associações das transações.

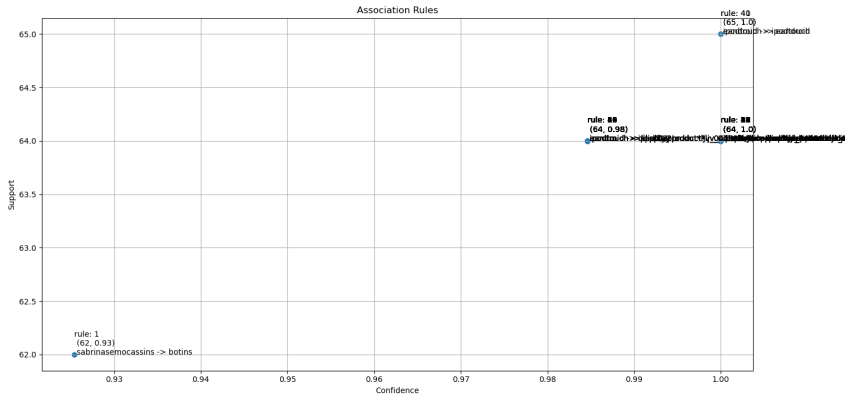


Figura 4: Produtos pouco acedidos mas sempre em conjunto.

Com base no *plot* e os dados seguintes, os itens que apresentam *eandroid* e *ipodtouch* nas regras 40 e 41, elas possuem um suporte de 65 e uma confiança de

100%. Observando a Figura 5 podemos também indicar a associação dos itens *ipad*, *iphone* e helicóptero tele comandado (regras seguintes), que possuem uma confiança similar com um suporte de 64.

```
rule: 33 - (64, 1.0): ['display.product*ljv_0459*helicopterotelecomandadoatravesiphone3/4/4s'] -> ['ipad1/2', 'eandroid']
rule: 34 - (64, 1.0): ['ipad1/2', 'eandroid'] -> ['ipodtouch']
rule: 35 - (64, 0.9846): ['ipodtouch', 'eandroid'] -> ['ipad1/2']
rule: 36 - (64, 0.9846): ['eandroid'] -> ['ipodtouch', 'ipad1/2']
rule: 37 - (64, 1.0): ['ipodtouch', 'ipad1/2'] -> ['eandroid']
rule: 38 - (64, 1.0): ['ipad1/2'] -> ['ipodtouch', 'eandroid']
rule: 39 - (64, 0.9846): ['ipodtouch'] -> ['ipad1/2', 'eandroid']
rule: 40 - (65, 1.0): ['eandroid'] -> ['ipodtouch']
rule: 41 - (65, 1.0): ['ipodtouch'] -> ['eandroid']
rule: 42 - (64, 0.9846): ['ipodtouch'] -> ['display.product*ljv_0459*helicopterotelecomandadoatravesiphone3/4/4s']
rule: 43 - (64, 1.0): ['display.product*ljv_0459*helicopterotelecomandadoatravesiphone3/4/4s'] -> ['ipodtouch']
rule: 44 - (64, 0.9846): ['eandroid'] -> ['display.product*ljv_0459*helicopterotelecomandadoatravesiphone3/4/4s']
rule: 45 - (64, 1.0): ['display.product*ljv_0459*helicopterotelecomandadoatravesiphone3/4/4s'] -> ['eandroid']
rule: 46 - (64, 1.0): ['ipad1/2'] -> ['display.product*ljv_0459*helicopterotelecomandadoatravesiphone3/4/4s']
rule: 47 - (64, 1.0): ['display.product*ljv_0459*helicopterotelecomandadoatravesiphone3/4/4s'] -> ['ipad1/2']
rule: 48 - (64, 1.0): ['ipad1/2'] -> ['ipodtouch']
rule: 49 - (64, 0.9846): ['ipodtouch'] -> ['ipad1/2']
rule: 50 - (64, 0.9846): ['eandroid'] -> ['ipad1/2']
rule: 51 - (64, 1.0): ['ipad1/2'] -> ['eandroid']
```

Figura 5: Dados do *Plot* 4

6.3 which products are the most visited?

Ao colocar a confiança a quase 0% e suporte acima de 120 para obter os itens que aparecem mais vezes nos registos. Recordando que isto é resultado dos dados filtrados por número de secções, pode existir algum item que não é representado aqui nos demais dados.

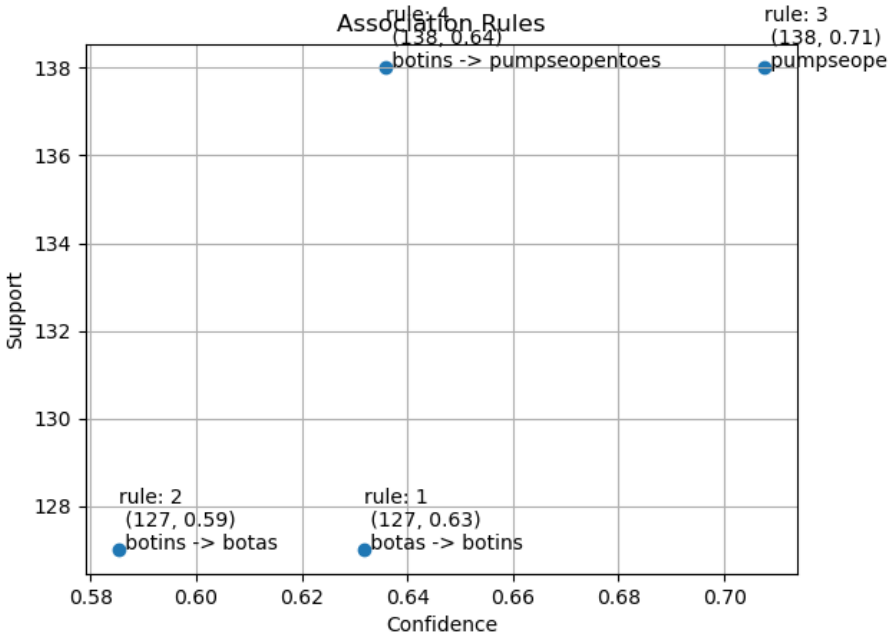


Figura 6: Produtos mais visitados

A Figura 6 mostras as 4 regras de associação dos produtos mais acedidos, que neste caso vem a ser as botas.

```
Decoded setOf-rules:
rules.len: 4
(supp, conf): LHS -> RHS
rule: 1 - (127, 0.6318): ['botas'] -> ['botins']
rule: 2 - (127, 0.5853): ['botins'] -> ['botas']
rule: 3 - (138, 0.7077): ['pumpseopentoes'] -> ['botins']
rule: 4 - (138, 0.6359): ['botins'] -> ['pumpseopentoes']
```

Figura 7: Dados do *Plot* 6

7 *Orange DM Análise*

Na nossa análise (*SoftKnow*) feita no conjunto de dados fornecidos pela *We-Commerce* foi possível chegar as seguintes recomendações demonstradas a seguir.

Conforme a Figura 8 mostra, os itens que são comprados ou consultados frequentemente na ordem decrescente. Os itens que encabeçam a lista são as botas, sabrinas e outro item com o código de produto *lon_4508*.

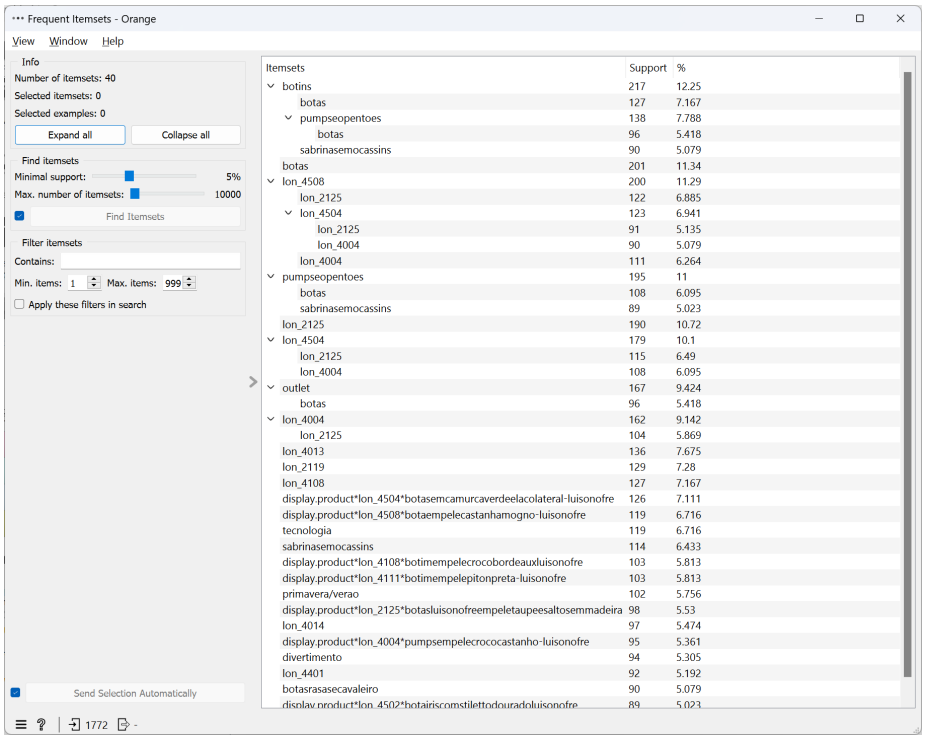


Figura 8: Conjunto de Itens

Em termos de associações e seguindo a nossa análise, sugerimos que sabrinas e botas na mesma página, também recomendamos façam uma segunda página com os seguintes produtos: ipod, ipad e helicópteros tele-comandados, ainda podem relacionar aparelhos androides na sugestão.

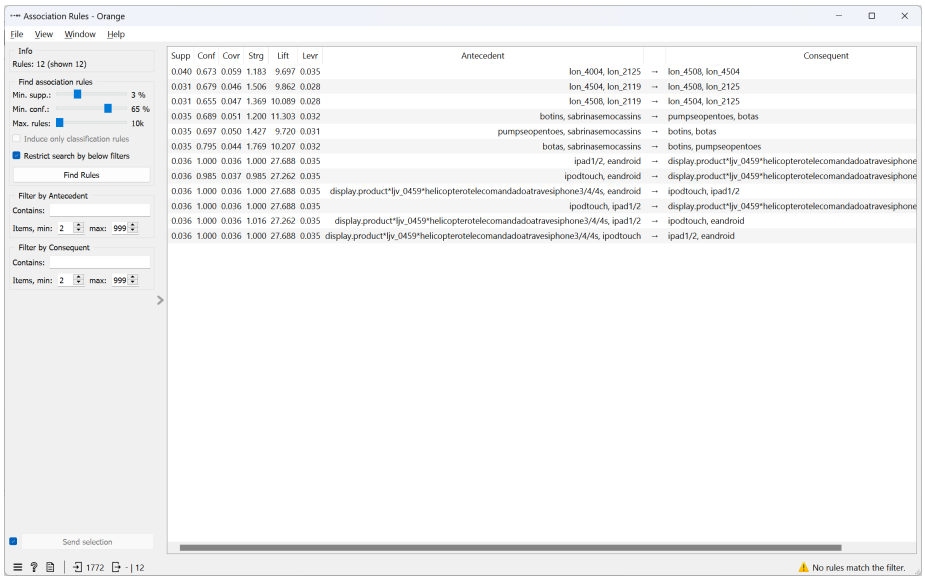


Figura 9: Regras de Associação

Recomendamos que itens na Figura **??** com código de produto sejam transcritos (descodificados) pois possuem uma relação entre si. A figura seguinte mostra uma distribuição do espaço de regras observadas acima.

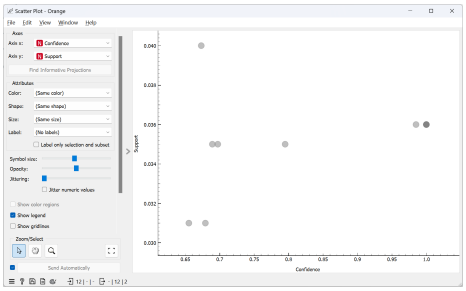


Figura 10: *Plot* das regras

8 *Implementação do código automático*

A implementação do código automático que faz a alíneas solicitadas no enunciado está dentro da diretoria "automatico"no executando o ficheiro "exercicio9.py".

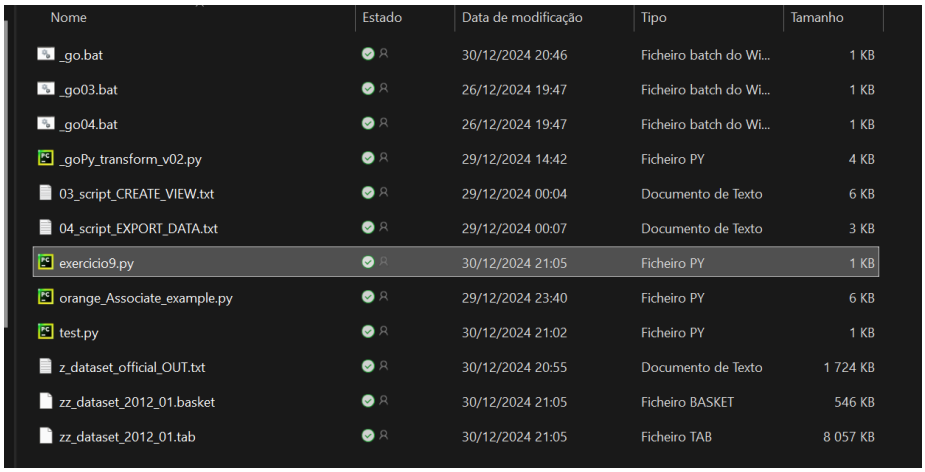


Figura 11: Diretoria automatico

Recomenda-se a substituição do *paths* no ficheiro envolvidos correspondentes a máquina do docente a executar.

9 Conclusões

A análise realizada neste relatório permitiu explorar os padrões de interação dos utilizadores na plataforma de comércio eletrónico "*We-Commerce*", com base em um extenso conjunto de dados. Foram aplicadas técnicas de mineração de dados, como a análise de regras de associação, para responder perguntas-chave, como:

Quais produtos devem ser agrupados em páginas para maximizar as vendas? Quais produtos, embora raramente visitados, apresentam altas associações? Quais produtos são os mais visitados e, portanto, merecem destaque? O processo incluiu etapas de seleção e limpeza de dados para garantir que apenas informações relevantes fossem consideradas. Dados inconsistentes ou pouco significativos foram eliminados, como acessos a páginas não relacionadas a produtos ou transações inválidas, garantindo assim maior precisão na análise. Além disso, sub-conjuntos de dados foram criados para otimizar a execução das análises, reduzindo a complexidade computacional sem comprometer os resultados.

Entretanto, foi percebido que uma limitação significativa do *dataset* atual é a ausência de uma coluna que associe os códigos dos produtos a seus respetivos nomes reais. Essa lacuna cria incertezas na interpretação de algumas regras e dificulta a aplicação direta dos resultados. Por exemplo, produtos altamente relacionados são identificados apenas por códigos, o que pode retardar decisões estratégicas ou mesmo comprometer a clareza do aprendizado por parte dos alunos. Assim, recomendamos que futuros modelos de dados incluam uma coluna explícita com os nomes reais dos produtos, facilitando o entendimento, a análise e o aprendizado.

Concluímos que o uso de técnicas avançadas de análise, juntamente com uma manipulação criteriosa dos dados, forneceu conceitos valiosos para a plataforma "*We-Commerce*". As recomendações aqui apresentadas podem contribuir para melhorar a experiência do utilizador, otimizar a disposição dos produtos e potencialmente aumentar as taxas de conversão da plataforma. Continuar a aprimorar o modelo de dados e as ferramentas analíticas será essencial para extrair ainda mais valor dos dados em análises futuras.

Glossário

IP Internet Protocol. 8